

PROJET COLLECTIF MATÉRIAUX

Intelligence Artificielle et Corrosion

Groupe 7 :

GINER LÉONORE
GRENIER MYRIAM
GUÉNÉGUAN MAËL
GUÉRIN CORENTIN
HOESCH AMÉLIE
HOU YING JUN
TRILLAT AGATHE

Tuteurs :

TER-OVANESSION BENOIT - MAÎTRE
DE CONFÉRENCE
TALLARON AUDE - PROFESSEURE
DOCUMENTALISTE

4ème année SGM - Semestre 2

2020-2021

Table des matières

1	Introduction	4
2	La corrosion	5
2.1	Qu'est-ce que la corrosion ?	5
2.2	La corrosion par piqûres et la corrosion caverneuse	5
2.2.1	La corrosion par piqûres	6
2.2.2	La corrosion caverneuse	7
2.2.3	Comparaison des deux modes de corrosion	8
3	Les alliages nickel	9
3.1	Généralités sur le nickel	9
3.1.1	Historique	9
3.1.2	Propriétés	9
3.1.3	Principaux domaines d'utilisation	10
3.2	Les différents alliages nickel	11
3.2.1	Alliages conventionnels base Ni	11
3.2.2	Alliages à haute entropie base Ni	12
3.2.3	Verres métalliques base Ni	13
3.3	Corrosion des alliages nickel	14
3.3.1	Pourquoi utilise-t-on des alliages base Ni contre la corrosion ?	14
3.3.2	Les différents alliages utilisés	15
4	L'intelligence artificielle et ses applications	18
4.1	Notions sur l'intelligence artificielle	18
4.1.1	Qu'est-ce que l'IA ?	18

4.1.2	Contexte historique	19
4.1.3	Deep Learning et Machine Learning	21
4.1.4	Techniques d'apprentissage machine	23
4.1.5	Présentation de trois types d'algorithme	24
4.2	L'intelligence artificielle dans les matériaux	25
4.2.1	Des outils algorithmiques spécifiques pour la science des matériaux	25
4.2.2	Les régressions	26
4.2.3	La classification	27
4.2.4	Autres utilisations de l'IA en science des matériaux : Clustering et Data Mining	28
4.3	L'intelligence artificielle et la corrosion	28
4.3.1	Des outils algorithmiques identifiés et testés	28
4.3.2	Formulation des inhibiteurs	29
4.3.3	Problèmes de corrosions atmosphérique et aqueuse	30
4.3.4	Autres exemples d'utilisations	32
4.3.5	Commentaires sur les trois principaux algorithmes utilisés en corrosion	33
5	Réalisation d'une database pour étudier la résistance des alliages Nickel à la corrosion	34
5.1	Sélection des paramètres de la base de données	34
5.1.1	Paramètres d'entrée de la base de données	35
5.1.2	Paramètres de sortie de la base de données	36
5.2	Acquisition de données	37
6	Programmation d'une IA pour aider au choix des matériaux	38
6.1	Réflexions préliminaires	38
6.1.1	Choix de l'approche	38
6.1.2	Choix de l'algorithme	39
6.2	Présentation du programme réalisé	41
6.2.1	Exploration et visualisation des données	41

6.2.2	Utilisation de l'intelligence artificielle	44
6.2.3	Paramètres d'influence	45
6.2.4	Utilisation du programme	46
6.3	Vérification de l'algorithme	47
6.4	Pistes d'amélioration	48
7	Conclusion et remerciements	49
8	Bibliographie	50

1 Introduction

La corrosion est un phénomène très surveillé par l'industrie, car elle entraîne la dégradation des matériaux, et notamment des métaux. Cela est particulièrement vrai pour l'industrie pétrolière. En effet, alors que la demande énergétique ne cesse de croître, et que les réserves pétrolières terrestres s'épuisent, l'exploitation off-shore est de plus en plus utilisée. Cependant, en pleine mer, les puits doivent pouvoir résister à de nouvelles contraintes (température, pression due à la profondeur...), surtout en considérant que les gisements exploités sont de plus en plus profonds, c'est-à-dire que les puits sont soumis à des conditions de plus en plus extrêmes. De plus, une eau de mer présente des éléments pouvant favoriser des formes graves de corrosion, avec notamment la présence d'organismes vivants qui ont, eux aussi, un impact. Tous les éléments cités favorisent donc la corrosion des puits, ce qui peut mener à des catastrophes. Par exemple, en 1987, une plateforme pétrolière en mer Caspienne s'est effondrée sous l'effet de la corrosion [1]. Pour des raisons financières, sécuritaires et environnementales, il est donc nécessaire de lutter contre ce phénomène. [2]

Une des solutions proposée depuis quelques années est l'utilisation d'alliages à base de nickel, très résistants à la corrosion. Cependant, sélectionner le plus résistant d'entre eux selon l'application et le milieu environnant est très difficile. Arcelor Mittal s'est ainsi penché sur la question de la dégradation de ses plateformes off-shore à cause d'une corrosion particulière : la corrosion cavernueuse. Dans le cadre d'une thèse, l'entreprise a alors demandé à Hugo Klinklin de trouver un alliage à base de nickel efficace et abordable pour parer à cette corrosion [3]. C'est de cette problématique qu'est parti notre projet.

En effet, nous nous sommes aussi intéressés à la sélection d'alliages à base de nickel, afin de mieux résister à la corrosion cavernueuse en eau de mer. Cependant, notre approche a été différente de celle de M. Klinklin, puisque nous souhaitons voir si l'intelligence artificielle (IA) pouvait nous aider dans ce processus complexe de sélection de l'alliage le plus efficace. En effet, au cours des dernières années, l'IA a émergé dans le domaine de la science et de la recherche, permettant de réaliser des tâches complexes et difficiles (voire impossibles) pour l'homme. Elle pourrait ainsi offrir de nouvelles possibilités dans la recherche sur la corrosion, sa conception et sa gestion opérationnelle.

Après quelques généralités sur la corrosion et les alliages Nickel, nous avons donc voulu nous intéresser à l'utilisation de l'intelligence artificielle dans le domaine des matériaux et dans la caractérisation de la corrosion. Nous avons aussi souhaité donner à ce projet une dimension expérimentale, en créant notre propre programme d'intelligence artificielle pour choisir au mieux un matériau résistant à la corrosion. Au préalable, ceci nécessitait l'établissement d'une base de données issue de nos études bibliographiques.

2 La corrosion

2.1 Qu'est-ce que la corrosion ?

La corrosion est un phénomène naturel, qui correspond à la dégradation d'un matériau et de ses propriétés sous l'action du milieu environnant. Ce phénomène a lieu suite à l'action de l'Homme, et plus précisément des métallurgistes. En effet, l'Homme extrait les métaux sous forme oxydée et les réduit afin de faciliter leur utilisation (métallurgie extractive). Cependant, cette réduction augmente le potentiel du métal, et le rend ainsi moins stable. La corrosion correspond donc à des réactions d'oxydation, afin de ramener le matériau vers sa forme d'origine, plus stable, c'est-à-dire la forme oxydée.

Il existe différents types de corrosion. On peut distinguer deux grandes classes : la corrosion sèche et la corrosion humide ou aqueuse. La corrosion sèche se passe généralement à haute température, lorsque le matériau est au contact d'un gaz oxydant (oxygène, soufre...). Ce type de corrosion est produit par des réactions ne mettant pas en jeu d'échange d'ions. La corrosion aqueuse, quant à elle, est un processus électrochimique. On a formation d'une pile de corrosion dans laquelle un courant circule, et des réactions d'oxydoréduction ont lieu. On a alors formation d'une anode, où se produit la réaction d'oxydation $M \rightarrow M^{n+} + ne^-$ (dissolution du métal) et d'une cathode, où se produit la réaction de réduction $Ox + ne^- \rightarrow Red$. Ces deux réactions ont lieu en même temps, générant ainsi un courant électrique total nul [4]. Il existe une dizaine de modes de corrosion humide, telle que la corrosion par piqûre ou la corrosion caverneuse, qui seront détaillées plus bas [5].

La corrosion a une action destructive qui peut aller jusqu'à entraver le bon fonctionnement de certaines installations. Il est donc important de prendre en compte ce phénomène lors de la conception des divers produits, car il a des conséquences importantes d'un point de vue économique. En effet, la corrosion induit des dommages considérables ayant un impact sur le prix de revient final du produit. Non seulement le remplacement des pièces endommagées représente un coût important pour l'entreprise, mais il faut également y ajouter le coût lié à la perte d'activité de l'installation en réparation [6] .

2.2 La corrosion par piqûres et la corrosion caverneuse

La résistance à la corrosion localisée des alliages au nickel est une propriété très étudiée. Dans notre cas d'étude, c'est ce type de corrosion, et plus particulièrement la corrosion par piqûres et la corrosion caverneuse, qui pose problème. Nous nous intéressons donc à ces deux types, afin de comprendre ce qu'il se passe lors de l'utilisation des alliages base nickel dans les puits de forage.

La corrosion par piqûres et la corrosion caverneuse sont des phénomènes qui interviennent princi-

palement à la surface de métaux passivables. La corrosion a lieu en plusieurs étapes, dont la première est l'amorçage, qui dans certains cas a lieu suite à une rupture locale du film passif. Cet amorçage est suivi d'une phase de germination au cours de laquelle les sites de corrosion se forment à la surface, et une phase de propagation au cours de laquelle les sites se développent latéralement et en profondeur. Il est donc nécessaire de comprendre le fonctionnement du film passif afin d'étudier ces deux types de corrosion.

2.2.1 La corrosion par piqûres

La corrosion par piqûres est très localisée, et peut rapidement se développer en profondeur. Très critique, elle est peu visible à l'œil nu, et est à l'origine de fissures pouvant mener jusqu'à la rupture de la pièce (cf figure 1). Il faut donc faire attention, car une pièce peut être perforée en quelques jours sans qu'une perte de poids/matière soit détectable. La corrosion par piqûres se produit lorsque le milieu environnant contient des halogénures, tels que du Br^- ou du Cl^- , mais également lorsque la surface présente des hétérogénéités [7]. Les piqûres se forment suite à une dépassivation locale du film. Les milieux contenant des sels halogénés, tels que l'eau de mer dans lequel sont placés nos puits de forage (les sels d'eau de mer sont composé d'environ 55% de chlore), sont très propices à ce type de corrosion.




FIGURE 1 – Corrosion par piqûres [7]

La résistance à la corrosion par piqûres des alliages de nickel peut être caractérisée par des calculs théoriques basés sur la composition, des tests en laboratoire et des mesures électrochimiques. Un test en laboratoire permettant de caractériser la résistance à la corrosion par piqûres est le test ASTM G-48 méthode C [8]. Le test ASTM G-48 consiste à immerger les matériaux dans une solution de $FeCl_3$ à température contrôlée. Dû à la présence d'ions, d'un pH faible et de conditions d'oxydation favorables, le milieu de la solution est très agressif. Il existe différentes versions de ce test mais la méthode C est celle utilisée pour la corrosion par piqûre des alliages au nickel, et nous permet d'accéder à la température critique d'apparition des piqûres (CPT). Par ailleurs, l'index PREN (pitting resistance equivalent number) permet également de comparer la résistance des alliages à la piqûre en fonction

de leur composition. Si la valeur de cet index est élevée, alors notre alliage sera résistant. Différentes formules permettent de le calculer, mais la suivante est la plus utilisée pour les alliages base Nickel : $PREN = Cr + 3,3(Mo + 0,5W) + 16N$. L'inconvénient de cet index est qu'il permet uniquement de comparer les différents alliages entre eux et non de prédire la résistance à la corrosion, et ne prend pas en compte la microstructure du matériau [9].

2.2.2 La corrosion caverneuse

La corrosion caverneuse, aussi appelée corrosion par effet de crevasse, se développe dans des zones confinées. En effet, dans des zones telles que les interstices, les recoins ou les joints non étanches, le transfert d'espèces y est très limité. Ainsi, les espèces oxydantes accèdent difficilement à ces zones, et on observe donc un appauvrissement en oxygène : on a création d'une pile d'aération différentielle entre la zone confinée et la surface. Suite à la corrosion du métal, le nombre de charges positives augmente. Les ions chlorure Cl^- chargés négativement, plus petits, et donc se déplaçant plus rapidement que les ions OH^- , sont alors attirés vers la zone confinée afin de compenser le surplus de charges positives. Les ions Cl^- viennent peupler la caverne, augmentant ainsi l'acidité, et faisant baisser le pH (entre 1-3). En effet, l'appauvrissement en OH^- est alors compensé par la réaction suivante : $H_2O \rightarrow H^+ + OH^-$ (dissociation de l'eau), entraînant une augmentation de la concentration en H^+ et donc une diminution du pH dans la zone confinée. Cette acidification du milieu dans la caverne engendre des conditions très agressives, détruisant ainsi la couche passivée [10].




FIGURE 2 – Mécanisme de la corrosion caverneuse [10]

Ce type de corrosion est dangereux car les cavernes ne sont souvent pas visibles de l'extérieur. Comme pour la corrosion par piqure, il existe différents tests normalisés afin de caractériser la résistance des alliages à la corrosion caverneuse. On trouve par exemple le test ASTM G-48 méthode D [8], qui permet de déterminer les températures nécessaires au développement d'une caverne. Ce test peut

être effectué de deux manières différentes. On peut exposer notre matériau à la corrosion caverneuse à une température donnée, pendant un temps donné, ou jusqu'à ce que l'amorçage commence. La deuxième méthode est d'augmenter régulièrement la température jusqu'à l'amorçage des cavernes. Cette deuxième méthode nous permet d'accéder à la température critique de corrosion par crevasse (CCT) (cf figure 3) [9, 11].

Alliage	Méthode D : Critical Crevice Temperature (°C)	Méthode C : Critical Pitting Temperature (°C)
Hybrid-BC1	> 85	> 85
686	> 85	> 85
C-22HS	> 85	> 85
59	> 85	> 85
C-2000	80	> 85
C-22	80	> 85
C-22HS vieilli	75	> 85
C-276	55	> 85
C-4	37	80
G-35	45	> 85
625	40	> 85
G-30	37,5	67,5
725 vieilli	25	85
825	5	30
316L	15	0

FIGURE 3 – Tableau des CCT et CPT pour différents alliages au nickel [9]

2.2.3 Comparaison des deux modes de corrosion

On remarquera ainsi que les deux phénomènes détaillés précédemment présentent beaucoup de similitudes. Ils sont tous les deux influencés par la température, les ions et le pH, et présentent une phase d'amorçage et une phase de propagation. Cependant, on distingue tout de même des différences. Par exemple, alors que les deux formes de corrosion se produisent en milieu chloruré, la corrosion caverneuse peut aussi se produire dans d'autres milieux, comme des milieux acides. Par ailleurs, la corrosion par piqûres peut se produire dans des solutions stagnantes ou circulantes, alors que la corrosion caverneuse est très favorisée dans des solutions stagnantes. Enfin, la corrosion caverneuse se produit à plus faible potentiel et à une durée d'amorçage plus courte [11].

3 Les alliages nickel

La corrosion dépend de différents facteurs. On trouve des facteurs liés à l'environnement tels que le pH, la température ou la concentration, mais également des facteurs de composition métallique. Les alliages de nickel sont ainsi regroupés en différentes familles en fonction de leur teneur en éléments d'addition (chrome, molybdène, cuivre et tungstène). Ces différentes familles permettent de les classer selon les caractéristiques de passivation.

Lorsque les aciers inoxydables ne peuvent pas être utilisés, les alliages de nickel apparaissent comme une bonne solution. Les entreprises qui produisent ces alliages évaluent leur résistance à la corrosion avec des tests en laboratoire. Ces tests permettent de comparer les alliages entre eux, mais pas d'accéder à leur véritable tenue, car ils ne reproduisent pas la durée d'exposition et les conditions réelles du milieu. Malheureusement les alliages nickel représentent une solution coûteuse qui ne peut pas toujours être envisagée.

3.1 Généralités sur le nickel

3.1.1 Historique

Le nickel est un métal utilisé depuis la nuit des temps. On le retrouve, allié à du cuivre, dans des pièces de monnaie datant de 235 ans avant J.C, ainsi que dans des armes fabriquées au début de l'Antiquité [12]. Néanmoins, il est utilisé dans l'industrie bien plus tard, puisqu'on considère qu'il est mis sur le marché en quantité importante au XIXe siècle.




FIGURE 4 – Élément nickel [12]

3.1.2 Propriétés

Le nickel est un métal de couleur blanche, parfois légèrement grisâtre. Il appartient au bloc d de la classification des éléments périodiques, ce qui en fait un métal de transition.

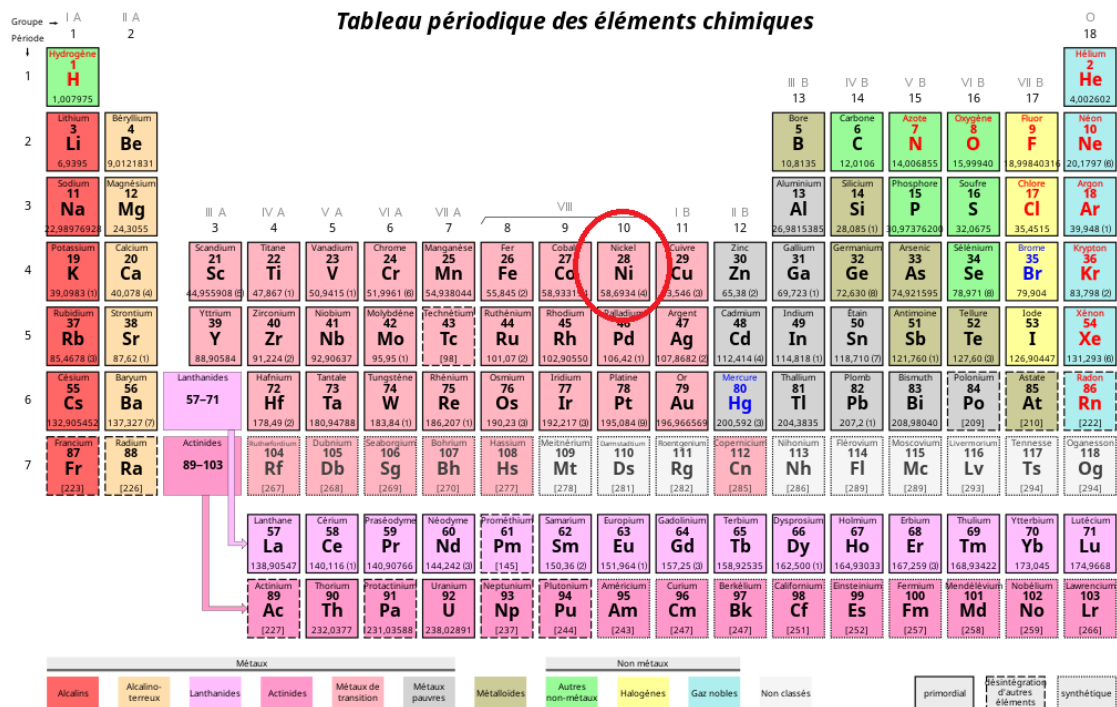


FIGURE 5 – Tableau périodique des éléments chimiques [13]

Il cristallise selon un réseau cubique faces centrées. Concernant ses propriétés physiques, c'est le métal le plus dur après le chrome. Il est malléable, c'est-à-dire qu'il peut facilement être déformé par laminage, et assez ductile, on peut donc l'étirer pour le mettre en forme sans qu'il se casse. Les principales valeurs qui le caractérisent sont résumées dans le Tableau 1 [14]. C'est également un bon conducteur de chaleur et d'électricité.

Module d'Young	Masse volumique	Conductivité thermique	Température de fusion	Température d'ébullition
210 GPa	8 900 kg/m3	83,7 W.m-1.K-1	1 454 °C	2 800 °C

TABLE 1 – Propriétés physiques du nickel (image réalisée par le groupe)

3.1.3 Principaux domaines d'utilisation

Le nickel est très largement utilisé dans des alliages pour améliorer leurs propriétés mécaniques. En général, il est utilisé pour améliorer les propriétés de résistance à l'attaque chimique et la résistance à la rupture de certains aciers, même à haute température. Il s'utilise ainsi dans des domaines très variés tels que l'industrie aéronautique, chimique, de la bijouterie [15]... Il est également utilisé dans des revêtements anti-corrosion.

3.2 Les différents alliages nickel

Dans ce sujet, il est question de trois types d'alliages en particulier, à savoir : les alliages conventionnels base Ni, les alliages à haute entropie base Ni et les verres métalliques base Ni. Nous proposons de définir ces trois familles de matériaux et de donner quelques généralités sur les alliages de nickel.

3.2.1 Alliages conventionnels base Ni

Il existe une multitude d'alliages base Ni dits "conventionnels". Le nickel est allié le plus généralement avec d'autres éléments métalliques comme le Fe, le Mn, le Cr, le Cu... Généralement, on distingue trois catégories d'alliages nickel. La première regroupe les alliages fer-nickel, qui sont principalement utilisés pour leurs propriétés physiques. En effet, sur ce type d'alliage, il est possible de jouer sur la dilatabilité, ainsi que sur la résistivité thermique avec la teneur en nickel comme l'illustre la Figure 6 :




FIGURE 6 – Variation du coefficient de dilatation (à gauche) et de la résistivité (à droite) en fonction de la teneur en nickel de l'alliage [16]

La deuxième catégorie correspond aux alliages cuivre-nickel, aussi appelés Cupronickel. Ces alliages sont appréciés pour leur très bonne résistance à la corrosion en milieu marin notamment. Ils sont donc très utilisés dans l'industrie maritime, ainsi que dans la fabrication de pièces de monnaie [15]. Nous développerons l'aspect anti-corrosion dans la suite (cf partie Alliage Ni-Cu).

Enfin, on distingue les superalliages, appelés aussi alliages à haute performance. Ces alliages sont réservés aux applications combinant hautes températures et efforts mécaniques intenses, c'est pourquoi on les retrouve principalement dans les moteurs d'avions, les turbines à gaz ou encore dans l'industrie pétrochimique. Ils sont composés d'une base de nickel à laquelle est ajoutée du chrome pour permettre une résistance à l'oxydation jusqu'à 1000°C. Puis, l'ajout d'aluminium permet de durcir l'alliage à chaud grâce à la précipitation du composé intermétallique Ni_3Al [17].

3.2.2 Alliages à haute entropie base Ni

Les alliages à haute entropie (AHE) sont une nouvelle famille de matériaux qui est étudiée depuis 2004 [18]. Ces alliages ne sont pas constitués d'un élément majoritaire qui sert de base, mais regroupent au minimum cinq composants différents en composition équimolaire [19]. Nous notons d'ailleurs qu'"alliage à haute entropie base nickel" n'est pas un terme très adapté, nous conviendrons dans la suite d'AHE contenant du nickel dans ses composants principaux. En général, les cinq (ou plus) composants principaux ont des concentrations comprises entre 5 et 35%. Des éléments mineurs peuvent être bien entendu ajoutés en faibles proportions.

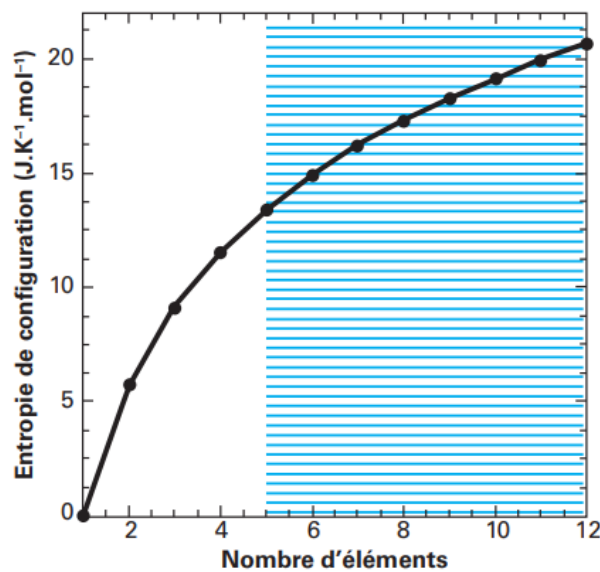


FIGURE 7 – Variation de l'entropie de configuration en fonction du nombre d'éléments ajoutés dans un alliage équimolaire (la zone hachurée correspond aux AHE) [20]

Pour définir complètement les AHE, citons trois spécificités qui caractérisent leur comportement :

- La première caractéristique concerne leur structure. En effet, ces alliages forment des solutions solides, et ne contiennent donc pas de précipités ou de composés intermétalliques. En effet, leur entropie élevée permet de stabiliser les solutions solides.
- Ils présentent une forte distorsion de la maille cristalline suite aux différences de volumes atomiques entre les différents éléments. Comme représenté sur la Figure 7, à partir d'un métal pur, il est possible de former une solution solide diluée, puis d'augmenter la concentration en éléments d'alliages pour aboutir à une maille très déformée.
- Enfin, la diffusion au sein de ces alliages est très lente à cause des fluctuations de liaisons chimiques au sein même du réseau.

Concernant les propriétés mécaniques de ces alliages, ils ont l'avantage de présenter une résistance mécanique assez élevée, tout en gardant une bonne ductilité par rapport aux alliages usuels

(cf Figure 8). Même si ces alliages sont encore assez méconnus, car développés très récemment, leurs caractéristiques mécaniques et leur stabilité thermique sont très prometteuses. Les AHE avec nickel présentent également une excellente résistance à la corrosion, ce qui explique qu'aujourd'hui on les retrouve principalement dans des revêtements de protection anti-corrosion.

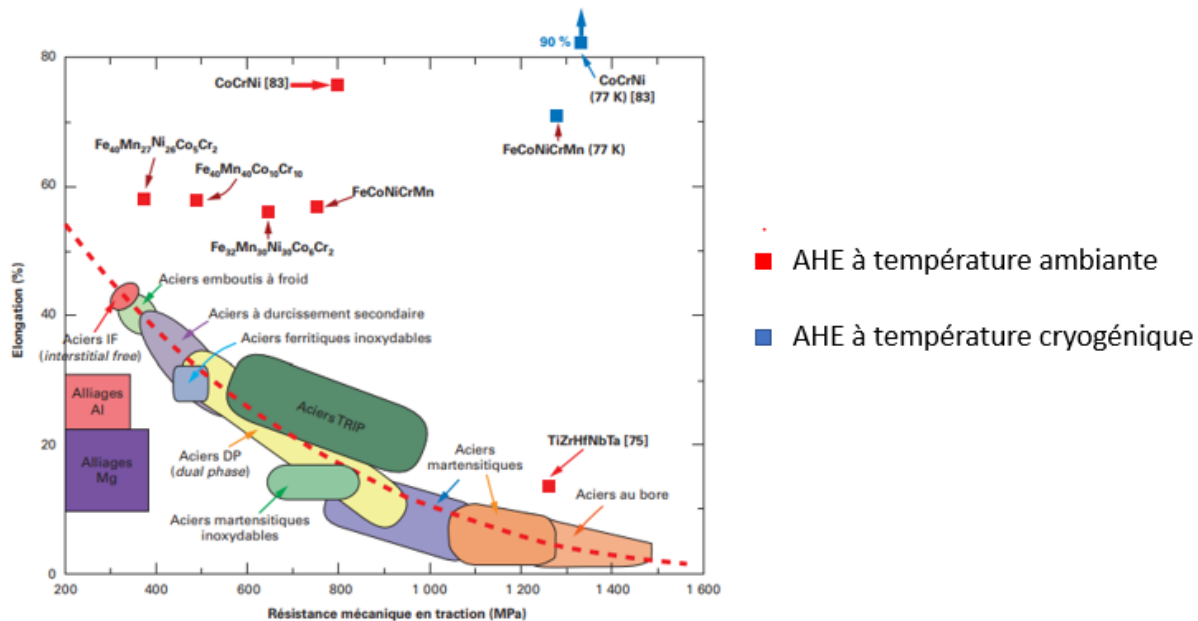


FIGURE 8 – Carte d'Ashby représentant l'allongement à la rupture en fonction de la résistance mécanique en traction pour différentes familles d'alliages, dont les AHE monophasés (carrés rouges et bleus) [20]

3.2.3 Verres métalliques base Ni

Les verres métalliques sont des matériaux très récents, puisqu'ils commencent à être produits en grande quantité dans les années 1980. La grande spécificité des verres métalliques est leur structure exclusivement vitreuse. En effet, ils sont obtenus à la suite de trempes extrêmement rapides depuis la phase liquide [17], ce qui permet de figer la microstructure à température ambiante, et ainsi d'empêcher la cristallisation. Ils sont donc caractérisés par une absence de réseau cristallin, et plus généralement d'ordre à longue distance [21] (cf Figure 9).




FIGURE 9 – Organisation d'un solide cristallin (à gauche) et d'un solide amorphe (à droite)

Leur structure leur confère ainsi des propriétés très différentes des métaux cristallins. Sur le plan mécanique, l'absence de grains et de joints de grain conduit à une forte dureté et une limite élastique et une ténacité élevées. En effet, la résistance mécanique (R_m) pour ce type d'alliages est aux alentours de 3 GPa. Néanmoins, ces propriétés mécaniques élevées le sont souvent au détriment de la ductilité, ce qui est le cas pour les verres métalliques. Il est également intéressant de noter que ces alliages ont une température de transition vitreuse (T_g) [22]. Ainsi, aux alentours de la T_g , les verres métalliques ont l'aspect d'un liquide visqueux qui facilite leur mise en forme. Aujourd'hui, les verres métalliques sont principalement utilisés dans des articles de sports (raquette de tennis, club de golf...) nécessitant des résistances mécaniques très élevées, ainsi que dans les hautes technologies (MEMS, stockage d'informations...).

3.3 Corrosion des alliages nickel

3.3.1 Pourquoi utilise-t-on des alliages base Ni contre la corrosion ?

Les alliages de nickel sont très utilisés dans l'industrie pour leurs propriétés mécaniques, mais également pour leur aptitude non négligeable de résistance à la corrosion. Il existe une multitude d'alliages de nickel résistants à la corrosion, qui sont classés en plusieurs familles en fonction de leurs teneurs en éléments d'additions (qui sont principalement le chrome, le molybdène, et le cuivre). Le chrome est essentiel pour permettre la passivation en milieu oxydant, et le molybdène assure la résistance aux milieux réducteurs. Ainsi, les alliages de nickel peuvent être utilisés pour résister à la corrosion généralisée ou la corrosion localisée, et sont une solution aux problèmes posés par l'apparition de piqûres, de corrosion caverneuse ou de fissures par corrosion sous contrainte. Voyons donc les grandes familles d'alliages utilisés pour des applications anti-corrosion.

3.3.2 Les différents alliages utilisés

— Nickel non allié et faiblement allié :

Afin de mieux comprendre le rôle des éléments d'alliages, commençons à nous intéresser aux propriétés de résistance à la corrosion du nickel en lui-même (ou faiblement allié). Les deux versions les plus répandues sont le Ni 200 et le Ni 201, toutes deux constituées à 99,5% de nickel. Dans des milieux très agressifs comme l'acide sulfurique, l'utilisation de ce type d'alliages n'est pas satisfaisante. En effet, l'aération augmente la vitesse de corrosion du nickel dans les solutions diluées d'acide sulfurique [9]. Pour avoir un comportement plus résistant, il est d'usage de rajouter des éléments d'alliages. En ce qui concerne l'eau de mer, plusieurs études montrent que la corrosion localisée n'est pas un problème pour le nickel à température ambiante dans l'eau stagnante. Cependant, en conditions réelles, l'eau de mer est en mouvement, et il est possible que l'on souhaite une résistance à la corrosion pour des hautes températures, notamment dans les échangeurs utilisant l'eau de mer comme fluide de refroidissement [9]. Dans ces conditions, il est préférable d'ajouter des éléments d'alliages au nickel.

— Alliages nickel-cuivre :

Les alliages à base de Ni-Cu sont composés d'environ 60% de nickel et de 30% de cuivre. Ils sont très utilisés, car l'ajout de cuivre améliore la résistance à la corrosion en milieu réducteur [23]. Ces alliages présentent une bonne résistance à la corrosion en eau de mer en mouvement jusqu'à des températures avoisinant les 400°C. Cependant, ils sont sensibles au phénomène de corrosion-érosion qui peut intervenir lorsque la vitesse de circulation de l'eau de mer devient trop importante. Pour rendre l'alliage plus résistant, on peut alors ajouter des éléments comme le fer, le chrome ou encore le manganèse, mais ces derniers diminuent la résistance aux attaques localisées en eau de mer stagnante. Il faut donc adapter la composition à l'utilisation voulue.

Il est intéressant de noter que ces alliages présentent naturellement des propriétés anti-fouling, c'est-à-dire qu'ils empêchent les organismes aquatiques (algues, coquillages...) de se fixer sur la coque des navires ou d'objets immergés [24]. Les Cupronickels sont donc largement utilisés en milieu marin, sur les coques de bateau, dans des circuits d'eau (tuyauteries, tubes échangeurs thermiques...). L'alliage 400 est par exemple utilisé pour la structure des plates-formes offshore dans les zones d'éclaboussures.

Cependant, dans les milieux agressifs comme l'acide chlorhydrique ou encore fluorhydrique, la présence d'oxygène et l'augmentation de température accélèrent considérablement les vitesses de corrosion, comme montré dans le Tableau 2. Ainsi, pour ce type de milieu, l'utilisation d'alliage Ni-Cu n'est pas recommandé.

Concentration en oxygène (ppm)	Vitesse de corrosion (mm/an)			
	112 °C/38 %HF		108 °C/48 %HF	
	Phase liquide	Phase vapeur	Phase liquide	Phase vapeur
< 5	0,24	0,17	0,28	0,08
< 500	0,43	0,30	0,56	0,10
1 500	0,79	1,24	0,70	0,61

TABLE 2 – Influence de l’oxygène sur la corrosion de l’alliage 400 dans des solutions d’acide fluorhydrique [9]

— Alliages nickel-chrome :

L’ajout de Cr favorise la croissance d’oxyde protecteur riche en Cr. Ainsi, l’augmentation de la teneur en Cr de 5% à 17% en poids conduit au changement de la surface du film de passivation en formant du Cr_2O_3 (cf Figure 10).




FIGURE 10 – Schéma de la formation d’un film passif de Cr_2O_3 (image réalisée par le groupe)

Cependant, les alliages Ni-Cr ne sont presque pas utilisés tels quels, car il est plus intéressant d’ajouter d’autres éléments d’alliages, comme nous le verrons dans la suite. Retenons donc qu’en général, l’augmentation de la teneur en Cr améliore les propriétés de protection des films passifs dans les alliages de nickel.

— Alliages nickel-chrome-molybdène :

Cette famille d’alliages est la plus riche de toutes les familles d’alliages de nickel. Ces métaux ont d’excellentes propriétés concernant la résistance à la corrosion. En effet, ils présentent une très bonne résistance dans des milieux agressifs tels que l’acide sulfurique ou encore l’acide chlorhydrique. Notons que le molybdène est l’élément d’addition favorable à la résistance en milieu chlorhydrique (cf Figure 11).




FIGURE 11 – Courbe d'iso-corrosion 0,1 mm/an d'alliages Ni-Cr-Mo dans une solution d'acide chlorhydrique [9]

Ces alliages résistent donc très bien à la corrosion localisée dans l'eau de mer contaminée par des chlorures. Les plus résistants à l'apparition de piqûres sont notamment les alliages Hybrid-BC1, 59, 686, C-2000 et l'alliage 2120, dont la teneur en azote augmente la résistance. De plus, dans l'eau de mer en mouvement à haute température, ces alliages offrent également une bonne résistance à la corrosion généralisée : la vitesse de corrosion est de l'ordre de 0,025 mm/an. Ainsi, ces alliages sont majoritairement utilisés pour des équipements dans la chimie de process incluant de fortes concentrations en chlorures, mais également dans des composants de haute sécurité exposés à l'eau de mer [25].

4 L'intelligence artificielle et ses applications

4.1 Notions sur l'intelligence artificielle

Maintenant que nous nous sommes intéressés à deux des termes principaux de notre sujet, la corrosion et les alliages aux nickel, il est temps de nous concentrer sur le troisième : l'intelligence artificielle.

L'intelligence artificielle (IA) existe depuis le milieu des années 1950. À l'origine, l'IA a été créée afin de simuler sur des Machines les différentes facultés de l'intelligence (humaine, animale, végétale ou sociale). Elle se basait sur le principe que toutes les capacités (raisonnement, calcul,...) peuvent être décrites parfaitement afin de pouvoir les reproduire sur ordinateur [26]. Mais qu'est-ce qu'une IA exactement ? C'est ce que nous allons définir dans cette partie.

4.1.1 Qu'est-ce que l'IA ?

Il existe de nombreuses définitions de l'intelligence artificielle, mais nous allons nous concentrer sur une seule définition donnée par D. Pastre : « L'Intelligence Artificielle (IA) est la science dont le but est de faire faire par une Machine des tâches que l'homme accomplit en utilisant son intelligence » [27]. D'après cette définition, l'IA servirait donc à remplacer l'humain. Or, un ordinateur ne possède pas de cerveau, il n'est pas capable de réaliser une tâche par lui-même. Il faut la lui inculquer, et c'est à ce problème que s'attelle l'IA. En effet, l'IA concerne tous les cas pour lesquels il n'est pas possible de créer un algorithme simple pour résoudre le problème, où il n'y a pas de suite d'opérations ordonnées et bien définies qui permettent d'obtenir rapidement un résultat. Afin de bien comprendre le principe, prenons l'exemple des échecs : il existe un nombre fini de combinaisons ou situations possibles, mais les analyser toutes à l'aide d'un algorithme prendrait des siècles. Nous voyons donc bien là l'intérêt de l'intelligence artificielle, qui va plutôt s'adapter au comportement du joueur dans chaque situation.

Nous pouvons alors nous ramener à la définition de JL Laurière [28], simple, mais qui résume très bien l'enjeu : « Tout problème pour lequel aucune solution algorithmique n'est connue, relève à priori de l'Intelligence Artificielle. » Si l'on additionne cette définition avec le principe de base de l'IA qui est de mimer l'intelligence humaine, on se retrouve donc avec une définition plutôt vague, qui contient des domaines très variés, allant de la reconnaissance de formes aux jeux vidéos. Nous allons donner des exemples plus précis de son utilisation dans les sous-parties suivantes.

4.1.2 Contexte historique

L'intelligence artificielle a connu de nombreuses avancées majeures. Elle a cependant connu plusieurs périodes de désintérêt, notamment de 1974 à 1980 à cause d'une limitation de puissance de calcul des machines et du manque d'investissements. Son origine remonte aux années 1950, même si plusieurs théories ont été évoquées avant cette période. [29]

- En 1950, Alan Turing, avec la Machine de Turing, mathématise l'intelligence humaine. Il réalise le test de Turing, qui permet d'observer la capacité d'une Machine à entretenir une conversation humaine.
- En 1956, la conférence de l'Université de Dartmouth est organisée par John Mc Carthy et Marvin Minsky, avec la présence d'une vingtaine de scientifiques, dont Alan Turing. C'est durant cette conférence que l'intelligence artificielle acquiert son nom, ainsi que son but, modéliser l'intelligence humaine.
- En 1958, John Mc Carthy crée le langage LISP, qui était utilisé dans la programmation d'IA, et développé au Massachusetts Institute of Technology (MIT). Le LISP, dont le terme a été formé à partir des mots anglais *list processing* (traitement de listes), est la plus ancienne famille de langages de programmation. Il est devenu un langage très utilisé dans la recherche en IA dans les années 70 et 80. [30]

C'est seulement en 1959 que la notion de Machine Learning est évoquée par l'informaticien A. Samuel, ainsi que la nécessité d'apprendre à l'IA l'ensemble des connaissances humaines basiques. Pour clarifier les informations dont nous parlons, nous pouvons donner comme exemple le fait que « si l'on coupe un morceau de beurre en deux, on obtient deux morceaux de beurre, mais si l'on coupe une table en deux, on n'obtient pas deux tables » [29]. Cet exemple nous paraît trivial, mais un ordinateur n'est pas capable d'intégrer tout seul ce raisonnement, il faut le lui inculquer.

L'image ci-dessous permet de situer quelques nouvelles applications de l'IA au cours du temps :

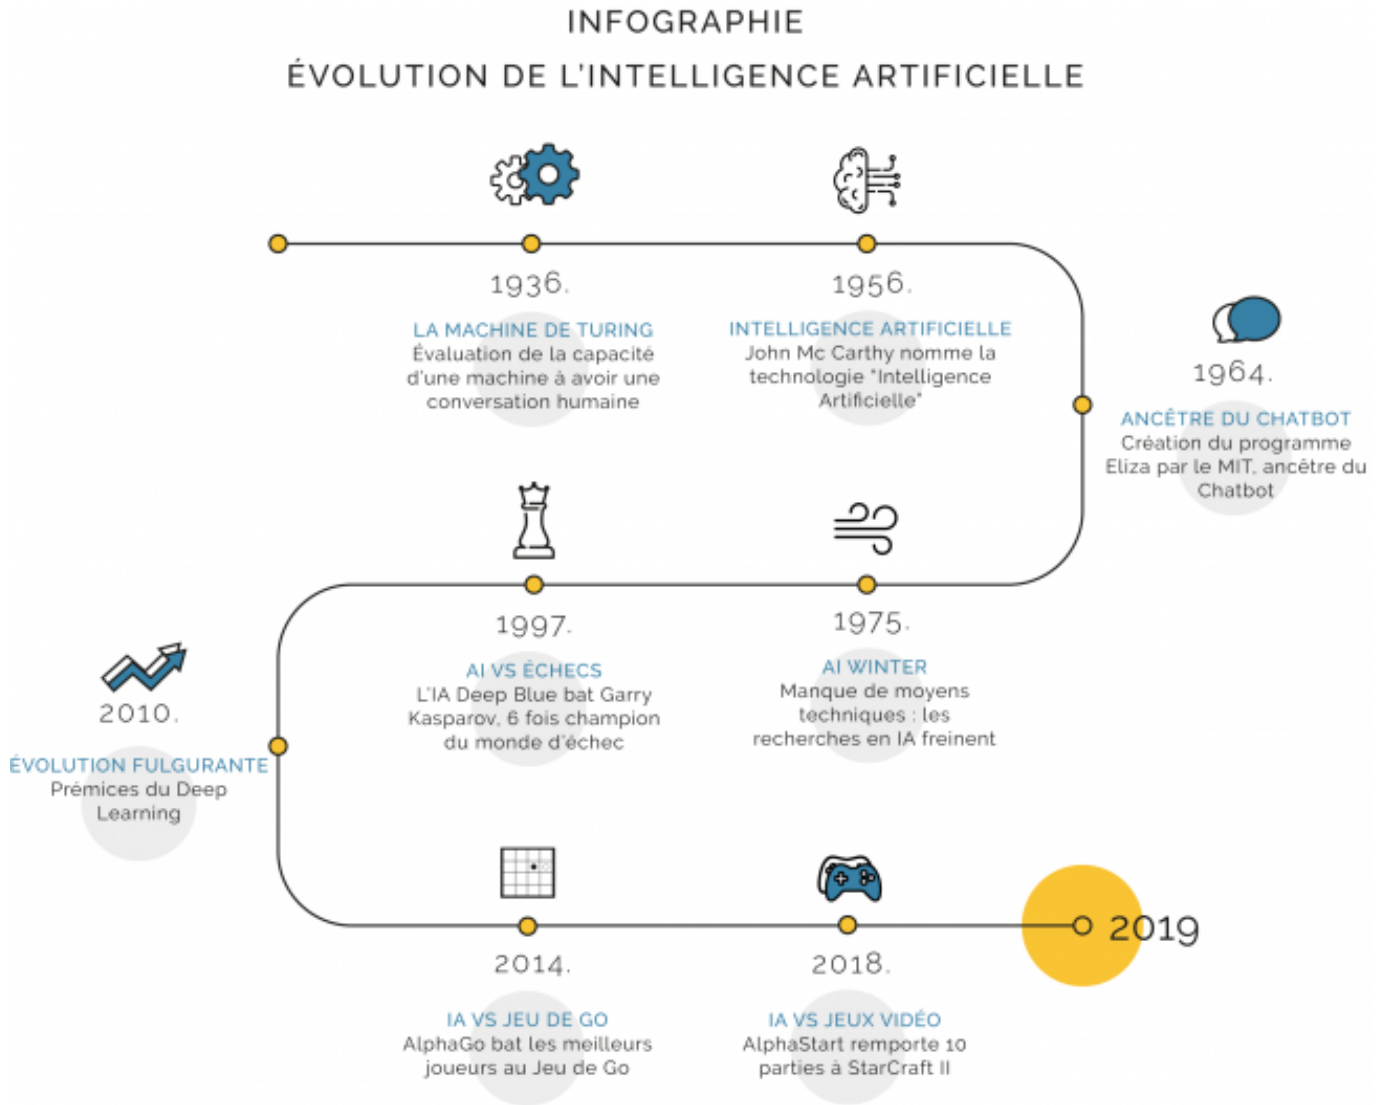


FIGURE 12 – Infographie sur l'intelligence artificielle [29]

A partir des années 2000, les ordinateurs ainsi que les smartphones permettent aux recherches de l'IA de se développer et de se diversifier. Le Deep Learning, qui est une sous-catégorie du Machine Learning (lui-même une sous-catégorie de l'intelligence artificielle, les deux termes seront davantage expliqués dans la partie suivante), a alors connu un grand développement grâce à plusieurs avancées techniques. Parmi ces avancées, on compte l'augmentation de la puissance des cartes graphiques qui sont responsables de la production d'images sur l'écran, l'accès en open source du Machine Learning ou encore le développement de framework spécialisées en Deep Learning. Un framework désigne un ensemble de composants logiciels, qui sert à créer les fondations ainsi que les grandes lignes de tout ou d'une partie d'un logiciel. En quelque sorte, le framework peut être considéré comme le squelette d'un logiciel.

Les années 2010 sont marquées par l'ouverture de centres de recherche en intelligence artificielle des

plus grandes entreprises, comme Facebook, Amazon, Microsoft, Apple, . . . Cette période est également marquée par la victoire de différents programmes d'IA contre des champions de jeux : Watson (IBM) au jeu télévisé *Jeopardy!*, ainsi qu'à un concours d'éloquence, AlphaGo (DeepMind) au jeu de Go, AlphaStar (DeepMind) qui remporte 10 parties contre un professionnel au jeu vidéo StarCraft II, ou Pluribus (Facebook) qui bat 5 des meilleurs joueurs de Poker au monde simultanément. [31]

L'IA a donc connu une évolution qui lui permet aujourd'hui d'imiter, voire de surpasser les humains dans plusieurs jeux, mais aussi d'imiter le langage naturel et de tenir une conversation. Parmi toutes ces avancées, nous identifions deux approches qui se démarquent particulièrement : le développement du Machine Learning, puis du Deep Learning. Nous allons développer leur principe dans la partie suivante.

4.1.3 Deep Learning et Machine Learning

Lorsque l'on entend parler d'intelligence artificielle, on entend plusieurs termes qui sont souvent mélangés : IA, Deep Learning (apprentissage profond) et Machine Learning (apprentissage Machine). Ces trois mots sont en fait reliés les uns aux autres, le Deep Learning étant une sous catégorie du Machine Learning, qui est lui-même une sous catégorie de l'IA (figure 13).




FIGURE 13 – Relations entre IA, Machine et Deep Learning [32]

Comme vu précédemment, l'intelligence artificielle regroupe énormément d'applications très différentes les unes des autres. Par exemple, dans le jeu de morpions, il y a la possibilité de réaliser une IA très simple avec des conditions *if* qui va créer un adversaire fictif. Le même principe est retrouvé dans beaucoup de jeux sur ordinateurs.[33] Cependant, cela crée des adversaires ou des scénarios stéréotypés, et ne convient que pour des problèmes assez simples. En effet, en utilisant uniquement des conditions *if*, nous n'obtenons pas un adversaire qui s'adapte au comportement du joueur, mais uniquement qui réagit par une réponse prédéfinie et limitée par les conditions rentrées par le créateur du jeu. De même, le scénario créé est répétitif, avec sans cesse les mêmes réactions. Nous voyons donc

bien que pour une application plus complexe, avec une infinité de choix ou de caractéristiques, un tel programme n'est pas possible, car il n'est pas possible de résumer toutes les possibilités par une liste de conditions. Un bon exemple d'un tel cas est celui de la reconnaissance faciale. Il n'est pas possible d'utiliser un programme aussi simple que celui du morpion, car les formes d'un visage sont trop complexes. C'est ici que l'on retrouve l'intérêt du Machine Learning.[32]

Le Machine Learning est utile dans le cas où l'on cherche à classer un objet, à en détecter un, ou encore lorsque l'on cherche à identifier un lieu ou une scène. Il se base sur des exemples donnés lors d'une phase d'apprentissage. Les algorithmes produits peuvent être assez simples, comme l'algorithme des k plus proches voisins.[34] Pour réaliser un programme se basant sur le Machine Learning, il faut tout d'abord regrouper tous les éléments à identifier. On sélectionne alors manuellement les points importants qui permettent de classer les éléments, afin d'entraîner le programme. Ce dernier va alors référencer tous les points qui vont lui permettre d'identifier un nouvel objet, puis les classer (figure 14).

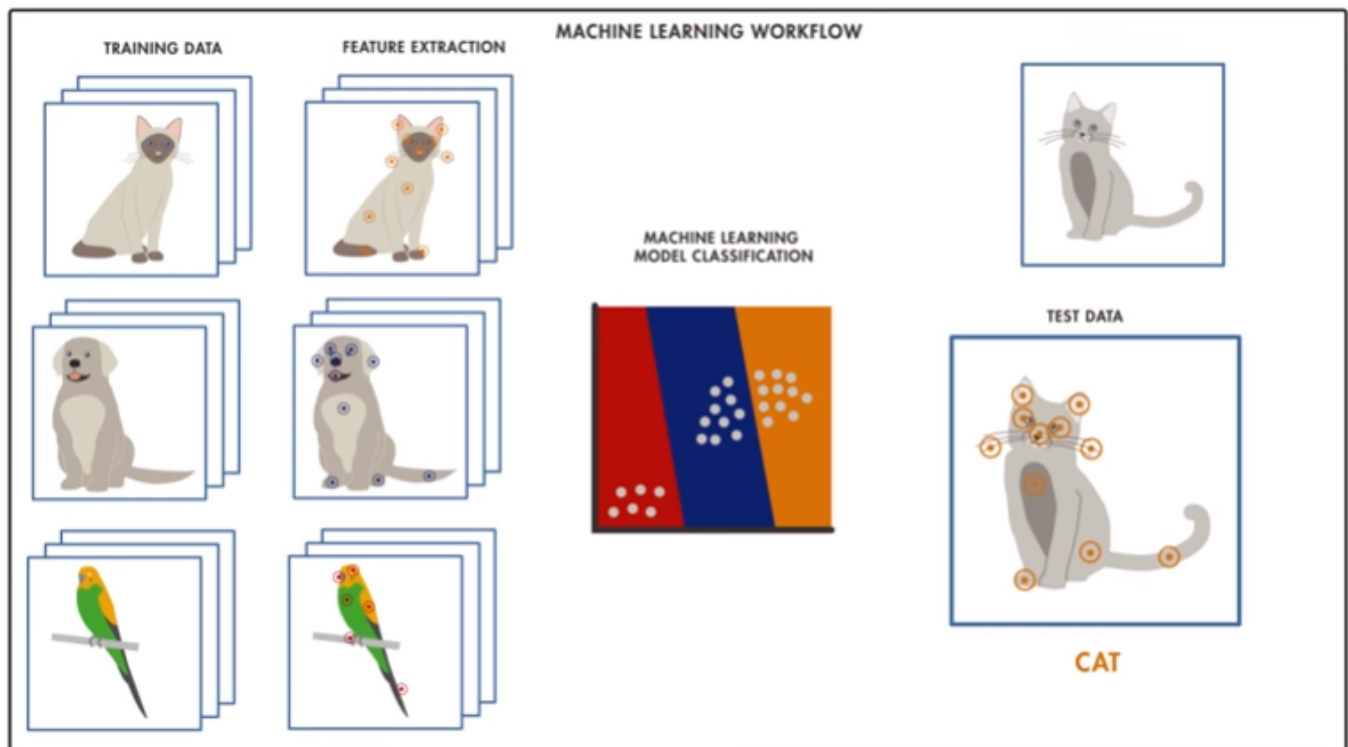


FIGURE 14 – Principe de fonctionnement d'un algorithme de Machine Learning [34]

Cependant, ces dernières années, c'est un autre type d'algorithme qui a permis de faire de grandes avancées, le Deep Learning. C'est un cas particulier du Machine Learning. Un algorithme de Deep Learning a la même fonction qu'un algorithme de Machine Learning, c'est-à-dire classer des éléments en fonction de caractéristiques communes. Cependant, la différence entre les deux réside dans le fait que le programme est nourri d'une très grande quantité de données qu'il s'occupe de classer lui-même

dans des catégories. Il n'y a donc pas d'étape de définition des caractéristiques importantes, et on suit un schéma tel que sur la figure 15. Il est efficace là où les autres types d'algorithme d'IA échouent, c'est-à-dire dans les domaines où le cerveau est lui aussi doué : la reconnaissance d'objets dans une image (par exemple, le détecteur d'objets YOLO) ou la transcription de discussion orale en texte. [34] Cependant, un tel programme aura besoin d'un plus grand nombre de données, sans quoi il ne sera pas capable de reconnaître et de classer les éléments avec une certitude suffisante.

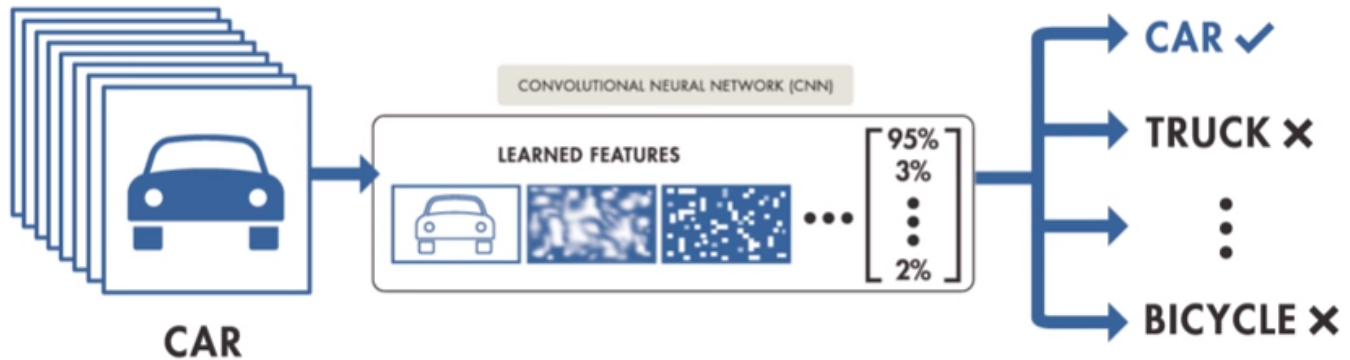


FIGURE 15 – Principe de fonctionnement d'un algorithme de Deep Learning [34]

Maintenant que nous avons présenté le Machine Learning et le Deep Learning, comment choisir entre les deux ? De manière générale, si l'on n'a pas un grand nombre de données (de l'ordre de plusieurs milliers) ou de très bon matériel informatique (comme une carte graphique très performante), il vaut mieux choisir le Machine Learning, car le Deep Learning sera trop complexe. Bien que le Deep Learning soit plus long à mettre en place et nécessite un grand nombre de données, il est aujourd'hui très utilisé, car il donne des résultats plus justes, et il n'y a pas besoin de passer par une étape de définition des caractéristiques.

4.1.4 Techniques d'apprentissage machine

Comme dit précédemment, que l'on choisisse le Deep Learning ou le Machine Learning, le programme doit passer par une phase d'apprentissage. Il existe 3 types d'apprentissages, que nous allons définir ci-dessous : [35]

- L'apprentissage par renforcement : le programme apprend grâce à des récompenses ou des punitions en fonction de ses actions. Il va donc chercher à maximiser l'espérance des récompenses grâce aux retours d'expérience. Cette technique est notamment utile dans les jeux et la robotique.
- L'apprentissage supervisé : la personne réalisant le programme donne des exemples étiquetés. Par exemple, on donne au programme une image d'un chien, puis on lui donne comme information qu'il s'agit d'un chien. Il faut donc créer une fonction qui est capable de reconnaître les éléments dans les images qui permettent d'identifier et de classer les éléments.

- L'apprentissage non supervisé : contrairement à l'apprentissage supervisé, les exemples sont ici non étiquetés. Le programme va donc rassembler tous les exemples les plus proches dans une catégorie. La machine doit donc savoir organiser les connaissances. Si l'on reprend l'exemple des chiens, ici l'utilisateur donne des images de chien et la machine doit les regrouper toute seule dans une catégorie en reconnaissant les points similaires.

L'apprentissage supervisé est un type d'apprentissage qui est particulièrement utile dans le cas du Machine Learning, car un algorithme de Machine Learning a besoin qu'on lui donne les caractéristiques à utiliser pour classer les éléments. L'apprentissage non supervisé est quant à lui fortement relié au Deep Learning, qui n'a pas besoin qu'on lui présente les caractéristiques.

4.1.5 Présentation de trois types d'algorithme

Nous allons maintenant vous présenter trois types de programmes qui peuvent être utilisés afin de créer une IA, et plus particulièrement une IA utile dans la corrosion.

Le premier algorithme est celui des Réseaux de Neurones artificiels (ANN), qui imitent le fonctionnement du cerveau. Ils sont très utilisés dans le Deep Learning, et permettent de traiter un grand nombre d'informations. L'idée de faire un parallèle entre le cerveau et les machines de calculs date de 1943, avant même les premiers ordinateurs, et a été émise par le mathématicien Walter Pitts et le neurophysiologiste Warren McCulloch. [36]. De manière générale, les ANN sont formés par des assemblages d'objets élémentaires, les neurones formels. Chaque neurone possède des connexions avec les neurones qui l'entourent, c'est-à-dire qu'ils possèdent des synapses. Ces neurones sont organisés en couches, avec une couche d'entrée et une couche de sortie, et la possibilité de rajouter davantage de couches entre les deux. La couche d'entrée va recevoir des informations. Chaque neurone de cette couche va alors prendre les informations reçues et leur appliquer une combinaison linéaire. L'information de sortie du neurone est alors transmise en tant que signal d'entrée à la couche suivante. Chaque neurone va donc réaliser une opération assez simple, mais c'est leur nombre et leur organisation qui permet d'obtenir un réseau complexe. [37, 38]

Concernant les deux autres algorithmes que nous souhaitons vous présenter, Support Vector Regression et Random Forest (respectivement SVR et RF), les utilisations sont sensiblement les mêmes que pour les Réseaux de Neurones artificiels.

La SVR est une approche alternative aux ANN, qui va construire une fonction en cherchant à minimiser les erreurs. [39]. Cette technique permet de traiter des vecteurs de dimensions importantes et ainsi d'intégrer plusieurs paramètres dans la prédiction. [40]

Nous terminons cette présentation des algorithmes par une légère précision sur les Random Forest. Cet algorithme est le plus récent des trois, et le plus raffiné en terme d'approche algorithmique. En effet, le Random Forest est un assemblage d'arbres de décision, chaque arbre de décision constituant

un estimateur indépendant des paramètres de sortie. Ainsi, la Random Forest est un assemblage d'estimations partielles du problème ; qui sont moyennées pour donner un résultat final. [41, 42]. En cela, l'approche Random Forest est beaucoup plus intuitive que les deux autres algorithmes. De plus, le Random Forest sélectionne ses paramètres d'entrée au hasard afin que chaque arbre traite des données sensiblement différentes. De ce fait, l'algorithme est réputé pour être moins sensible à des données déviantes. En effet, pour des ANN et des SVR, l'ajout de quelques données peu cohérentes peut rendre le programme inutilisable et fausser tout l'entraînement des IA.

4.2 L'intelligence artificielle dans les matériaux

Maintenant que les concepts d'IA, Machine Learning, Deep Learning, ainsi que les différents types d'apprentissage ont pu être définis, nous nous attèlerons à en expliquer le lien avec le domaine des matériaux. Pour rappel, notre sujet s'intitule « IA et corrosion ». Ce lien peut paraître à première vue incongru étant donné qu'il lie deux branches de sciences complètement différentes : les sciences informatiques et les matériaux. De plus, l'IA peut paraître un sujet de recherche à elle seule.

Les perspectives de l'IA dans le domaine scientifique sont importantes. L'utilisation des algorithmes Machine Learning et Deep Learning marque un tournant dans la manière dont fonctionne la recherche. On pourrait résumer l'introduction de l'IA par une citation tirée d'un article de 2019 du site web "courant constructif" : « nous sommes tout simplement en train de réinventer la manière dont nous inventons ». [43]

4.2.1 Des outils algorithmiques spécifiques pour la science des matériaux

Concentrons-nous maintenant sur la science des matériaux, domaine qui nous concerne ici, et n'échappe pas à la tendance de l'IA. En effet, plusieurs projets voient le jour dans le domaine du traitement d'image pour la cristallographie par exemple [44], la valorisation des déchets [45] ou encore pour la sélection des matériaux [46].

La sélection des matériaux est un enjeu particulièrement important dans l'industrie. La question du choix des matériaux nécessite de manière récurrente des algorithmes de l'apprentissage supervisé et non-supervisé. Plusieurs algorithmes de ces deux approches sont fréquents dans les sciences des matériaux. On citera notamment les Random Forest (RF) et les Réseaux de Neurones Artificiels (ANN), très utilisés actuellement (cf partie 4.1.5). Plusieurs autres algorithmes, régulièrement utilisés en science des matériaux, sont consignés dans la table 3.

Type apprentissage supervisé	Type apprentissage non-supervisé
Support Vector Machine (SVM)	Artificial Neural Network (ANN)
Arbres de décision (DT)	Component analysis (PCA)
Random Forests (RF)	
K-nearest neighbors	

TABLE 3 – Récapitulatif des principaux algorithmes utilisés en science des matériaux [46, 47]

De nombreuses utilisations de l'IA sont possible dans le domaine des matériaux. Nous nous proposons de les présenter ci-dessous.

4.2.2 Les régressions

Les premières concernent les algorithmes de régression, qui visent en général à l'établissement d'un modèle empirique permettant de lier certaines conditions extrinsèques à des paramètres intrinsèques du matériau. On citera, par exemple, l'utilisation de l'IA pour caractériser l'évolution de la bande interdite d'un matériau semiconducteur en fonction de son état de déformation [48]. Ici, l'utilisation du Machine Learning présente l'avantage de ne pas limiter le nombre de paramètres à intégrer. Ainsi, une propriété matériau peut être prédite à partir d'attributs allant de sa composition à ses propriétés électroniques microscopiques, voire de son environnement [49]. L'exemple de la figure 16 illustre une régression de à trois paramètres.

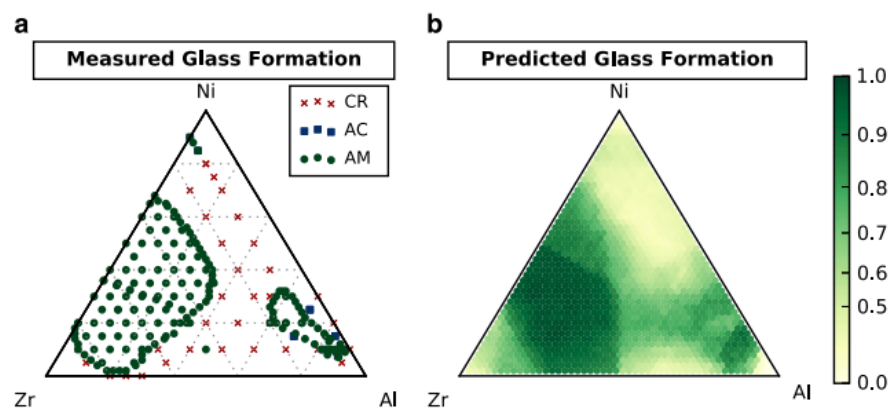


FIGURE 16 – Exemple de régression multidimensionnelle (3D) afin de prédire la probabilité de formation d'un verre à partir d'une composition ternaire. A gauche, les résultats expérimentaux de formation du verre. A droite, des résultats prédits à partir de l'algorithme de régression. [49]

Établir des régressions grâce à l'intelligence artificielle est une approche qui tend à se développer pour une autre raison. En effet, de nombreux projets de recensement des propriétés des éléments et des alliages voient le jour cette décennie. Le plus célèbre de ces projets étant peut être la Materials Genome Initiative [50], qui a permis de regrouper dans des bases de données communes des milliers

d'éléments et d'alliages. Ces nouvelles bases de données se destinent en toute logique aux algorithmes de Machine Learning [51].

Les régression présentent un panel algorithmique très varié, résumé dans la table ci-dessous.

Algorithmes de régression
Support Vector Regression (SVR)
Artificial Neural Network (ANN))
Arbres de décision (DT)
Random Forests (RF)
K-nearest neighbors (KNN)
ElasticNet
LASSO

TABLE 4 – Récapitulatif des principaux algorithmes de régression par ordre d'utilisation [52, 53]

Pour conclure sur la régression, cette approche, permettant d'obtenir des lois de comportement, a pour but ultime la simulation des matériaux. En effet, face à des enjeux de réduction des prix et de l'utilisation des matières, la simulation permet de réduire des étapes comme la formulation et le test d'un matériau.

4.2.3 La classification

Concernant le choix même des matériaux, la deuxième approche dite de la classification est très importante. Celle-ci consiste en la discrétisation en plusieurs catégories de matériaux en fonction de leurs propriétés, de leur aspect ou de résultats expérimentaux. On citera par exemple les méthodes d'arbre de décision, qui permettent de classer des matériaux sur la base de critères que l'algorithme détermine lui-même [54, 55].

Les algorithmes de classification sont de plus en plus courants. Par exemple, ils sont à la base de la reconnaissance faciale. C'est d'ailleurs sur ce principe qu'ils peuvent aider dans la caractérisation des matériaux. Pour appuyer ce point, on citera l'application du Machine Learning pour la thermographie au laser. En effet, si la reconnaissance d'un matériau grâce à son thermogramme est aujourd'hui courante, cela demande une comparaison manuelle avec des thermogrammes existants. Grâce au Machine Learning, cette tâche devient automatique, car les algorithmes de classification sont capables de lire un thermogramme, de le comparer avec une base de données, et de fournir le nom du matériau étudié avec plus de 95% de précision [56]. Cette application peut se révéler utile lorsque l'on cherche à catégoriser des matériaux de manière rapide, comme dans des usines de traitement des déchets.

Concernant les algorithmes de classification, on retrouve les Support Vector Machine (SVM), les arbres de décisions, les Random Forests (RF) et les régressions logistiques, ces dernières étant très utilisées dans le domaine de la classification.[57]

4.2.4 Autres utilisations de l'IA en science des matériaux : Clustering et Data Mining

D'autres approches sont aussi développées dans le domaine du choix des matériaux. On citera par exemple le problème courant de la réduction des variables d'un système. En effet, devant l'importante quantité de paramètres disponibles pour un matériau, il est parfois utile d'identifier des paramètres canoniques, c'est-à-dire des paramètres de base à partir desquels les autres découlent. Le Machine Learning, et plus spécifiquement l'apprentissage non supervisé, nous fournit ici une approche très intéressante pour ce problème : le Clustering.

Le but de cette méthode est de discrétiser les paramètres canoniques d'un système [58]. Cette technique se révèle particulièrement importante en amont d'autres techniques comme la régression ou le Data Mining.

En effet, une des dernières utilisation de l'IA pour le choix des matériaux est le Data Mining. Bien que la littérature sur les sciences des matériaux soit très importante et accessible à tous par le biais du web, il n'en reste pas moins qu'elle est particulièrement diverse en termes de formes et de qualité. Par ailleurs, pour ce qui est de la forme, la plupart des données matériaux disponibles n'est pas structurée en base de données, mais est plutôt présente sous forme de compte rendu d'expérience dans des articles. La récupération rapide de ces données peut paraître un problème insoluble pour un chercheur. Ainsi, l'approche du Data Mining tente de répondre à ce problème [59].

Le Data Mining est une technique d'apprentissage non supervisé qui consiste en l'identification de mots-clés (un paramètre matériau, des dimensions,...) et de structure de présentation (un tableau, un graphe,...), afin de récupérer les données d'un article. Le Data Mining peut aussi concerner des bases de données existantes, et constituer un outil de récupération intelligente des propriétés de matériaux dans divers formats de fichiers [60, 61].

4.3 L'intelligence artificielle et la corrosion

Après avoir parlé d'une utilisation assez générale des algorithmes de Machine Learning et de Deep Learning dans le choix des matériaux, nous allons maintenant nous concentrer particulièrement sur le domaine de la corrosion. Bien que nous travaillions spécifiquement sur des problèmes de corrosion par crevasse dans ce rapport, nous ferons ici référence à tout type de corrosion, l'idée étant de proposer un modeste état de l'art du domaine.

4.3.1 Des outils algorithmiques identifiés et testés

La recherche existante autour du Machine Learning et de la corrosion s'efforce, actuellement, de créer les conditions adéquates pour que l'IA devienne un véritable outil. Ainsi, la problématique des

articles est, bien souvent, de comparer des algorithmes IA pour le domaine, et non de faire avancer l'état de l'art sur la corrosion. Cela est caractéristique lorsqu'on introduit l'IA dans la recherche scientifique. En effet, il faut comprendre que l'intervention de ces algorithmes dans le domaine est encore récente, et trop peu démocratisée chez les chercheurs en corrosion pour que l'utilisation du Machine Learning se fasse de manière non anecdotique dans l'article.

Cependant, plusieurs algorithmes sont d'ores et déjà identifiés spécifiquement pour la corrosion. Dans ses travaux, l'équipe internationale du professeur Z.Pei identifie trois grandes familles d'algorithmes utilisées pour la corrosion [62]. Dans l'ordre d'importance d'utilisation, on a ainsi les Réseaux de Neurones (ANN), les algorithmes Random Forest (RF) et le Support Vector Regression (SVR) (cf partie 4.1.5 pour leur principe).

Dans la suite, nous présenterons plusieurs utilisations de ces trois algorithmes concernant des problèmes de corrosion.

4.3.2 Formulation des inhibiteurs

La formulation des inhibiteurs est l'application qui semble avoir fait l'objet de la plus grande littérature commune avec l'intelligence artificielle ces dernières années. On citera par exemple les deux études suivantes concernant leur formulation : *Elucidating Structure-Property Relationships in Aluminum Alloy Corrosion Inhibitors by Machine Learning* [63] et *Using high throughput experimental data and in silico models to discover alternatives to toxic chromate corrosion inhibitors* [64]. Dans ces études, les corrosionnistes ont comparé des algorithmes de Machine Learning entre eux, et les ont utilisés pour analyser l'efficacité d'inhibiteurs de corrosion. Ainsi, sont utilisés plusieurs algorithmes comme les Decision Tree (DT), les Random Forest (RF) ; et des algorithmes ANN (Réseaux de Neurones), dont nous ne nous étendrons pas sur le principe, car il a déjà été traité en partie (4.1.5).

Cette approche consiste à optimiser la formulation d'un inhibiteur. En entrée, on code un "set" de molécules de base, en y attachant certaines propriétés électroniques et quantiques. Puis, l'idée est de simuler des mélanges entre ces molécules et de comparer les inhibiteurs créés avec de vrais inhibiteurs, ainsi que leurs propriétés concernant la réduction de la corrosion.




FIGURE 17 – Illustration de l'utilisation d'un arbre de décision pour la validation d'un inhibiteur [63]

En pratique, un problème se pose : sur quels critères peut-on comparer objectivement des inhibiteurs ? Pour répondre à ce problème, on va réaliser du Clustering, comme défini précédemment. En réalité, on ne peut pas comparer réellement les inhibiteurs entre eux, mais on va construire au préalable, grâce à des algorithmes de Clustering, une sorte de "mind-map" permettant de classer les propriétés d'inhibiteurs, comme le montre l'image tirée du rapport de l'équipe du Pr.Galvao [63].

A partir d'un "set" de vrais inhibiteurs, l'algorithme de Clustering va créer cette "carte mentale", et ainsi pouvoir déterminer si, oui ou non, une proposition d'inhibiteur a des chances de présenter des propriétés utiles. De plus, l'utilisation de l'outil informatique permet d'augmenter de manière très nette le nombre de suggestions, ainsi que d'orienter ces suggestions vers des formulations qui semblent se détacher des autres au fur et à mesure de la simulation. Ce genre d'approche permettrait, à terme, de se passer de l'étape classique de formulation et d'expérimentation des inhibiteurs. Elle a pour mérite de réduire drastiquement la part d'intuition dans les combinaisons de groupements. Ainsi, on gagne du temps et on économise des réactifs.

4.3.3 Problèmes de corrosions atmosphérique et aqueuse

D'autres utilisations des Réseaux de Neurones sont très courantes dans des problèmes de corrosion. On peut citer par exemple les problèmes classiques de corrosions atmosphérique et aqueuse des métaux, qui nécessitent grandement ce type d'algorithme. Une approche très courante consiste à utiliser un Réseau de Neurones, ou tout autre algorithme équivalent, afin de réaliser des prévisions de comportement dans un milieu donné. Cela correspond à une régression. Ainsi, on fournit à l'algorithme un jeu de données avec des paramètres environnementaux en entrée, puis on lui donne le comportement en corrosion correspondant à ce milieu pour un acier donné [40].

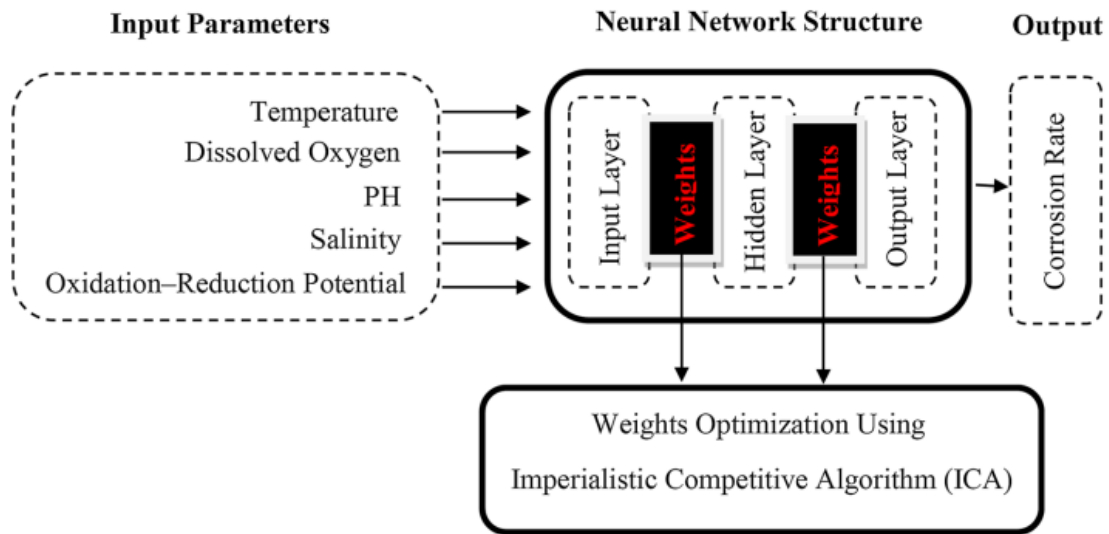


FIGURE 18 – Schéma d'un problème de corrosion aqueuse pour un acier 3C (L'article porte sur l'optimisation d'un réseau de neurone mais la structure générale reste la même) [40]

Cette approche permet de prédire, à partir d'un nombre réduit d'expérimentations sur l'acier ou l'alliage considéré, quasi-systématiquement son comportement en corrosion dans des conditions différentes de celles de l'expérimentation. Là où un algorithme de régression classique peut éventuellement extrapoler l'évolution d'une vitesse de corrosion en fonction d'un paramètre environnemental, les ANN permettent de lier cinq paramètres, voire techniquement plus. La caractérisation du comportement en corrosion est donc très complète. Concernant les paramètres en entrée, on retrouve à la fois des paramètres de composition, de structure, mais aussi et surtout des paramètres environnementaux comme la température, la salinité, l'oxygénation ou encore le pH, mais aussi des paramètres insoupçonnés et n'entrant habituellement pas en compte dans des études de corrosion comme le vent ou l'ensoleillement. Ce point soulève d'ailleurs le fait que l'IA offre la possibilité de croiser des bases de données. La table 19, issue des travaux du Pr.Yan et son équipe, illustre ce type de paramètres originaux.(cf figure 19)

Environmental Parameter	Exposure Test Site			Description
	Tsukuba	Choshi	Miyakojima	
T	14.5–15.5	14.7–15.3	23.9–24.0	°C; mean air temperature
RH	74.6–77.5	77.6–79.0	78.5–79.0	%; mean relative humidity
TOW	4088–4670	4629–4908	5113–5249	h; time of wetness
Precipitation	1103–1344	1511–1791	1899–2314	mm; precipitation
Wind	1.5–2.5	3.0–3.5	4.2–4.7	m/s; mean velocity of wind
Solar	4183–6274	4193–4901	5229–5260	MJ/m ² ; solar radiation
Cl ⁻	2.8–3.3	32.0–32.3	45.8–49.2	mg NaCl/m ² ·d; chloride deposition rate
SO ₂	3.7–5.3	4.9–5.1	2.1–2.4	mg SO ₂ /m ² ·d; SO ₂ deposition rate

FIGURE 19 – Illustration de la prise en compte de paramètres originaux dans une étude de corrosion atmosphérique [65]

D'autres algorithmes comme les Support Vector Regression et surtout les Random Forest ont pu être utilisés concernant ce problème spécifique [65, 66, 62]. Nous verrons d'ailleurs, plus bas, que les Random Forest sont probablement les plus conseillés pour ce genre d'application.

4.3.4 Autres exemples d'utilisations

Jusqu'ici, nous avons principalement présenté des applications tournant autour de la corrosion généralisée et des méthodes pour la contrer, comme les inhibiteurs. Cependant, d'autres types de corrosion font l'objet de recherches couplées avec l'IA.

On pourrait, par exemple, citer une équipe de l'université de Tianjin ayant travaillé sur la fragilisation des aciers 304L [67] avec de la corrosion sous contrainte. Cette équipe a réussi, grâce à un Réseau de Neurones, à calculer le CGR (correspondant à un taux de création des fissures) d'un acier 304L, en intégrant sept paramètres environnementaux au modèle. A noter que l'équipe du Pr. Shi a obtenu une corrélation à 95% par rapport à ses mesures expérimentales, ce qui est très correct. Ce genre de régression multidimensionnelle a été rendu possible par un Réseau de Neurones issu d'une librairie de Matlab. A noter cependant que les ANN sont probablement les moins accessibles des algorithmes parmi les trois présentés 6 .

On citera aussi des applications dans l'analyse des revêtements [68] et le Clustering de données de corrosion dans une approche de Data Mining [69]. On retiendra néanmoins la simulation des comportements en corrosion et la formulation des inhibiteurs comme les problèmes où il existe le plus de littérature liée au Machine Learning et au Deep Learning, les autres applications étant plutôt anecdotiques.

4.3.5 Commentaires sur les trois principaux algorithmes utilisés en corrosion

Nous avons jusqu'ici parlé indistinctement des applications de trois algorithmes : les Réseaux de Neurones (ANN), les Support Vector Machine (SVR) et les Random Forest (RF). Globalement, les Réseaux de Neurones sont clairement les algorithmes les plus utilisés dans la corrosion, ce qui est, en réalité, le cas pour tous les domaines scientifiques utilisant l'IA.

Le Random Forest a l'avantage, quant à lui, d'être assez simple d'utilisation comparé aux ANN et beaucoup moins sensible aux données déviantes. Ces points seront approfondis dans la dernière partie de ce rendu, qui présente l'utilisation d'un Random Forest pour résoudre un problème de corrosion. Ce point est mis en exergue dans l'article à l'origine de cette recherche [62]. Cependant, il faut garder à l'esprit que toutes les applications citées précédemment ne concernent pas que des Random Forest et présentent toutes des résultats globalement acceptables.

Ainsi, il nous est difficile de déterminer quel algorithme privilégier de manière générale. Cependant, tous les algorithmes ne présentent pas les mêmes avantages. Si les Réseaux de Neurones (ANN) présentent, dans l'ensemble, la meilleure efficacité de calcul, ces derniers sont aussi plus sensibles, comme les Support Vector Regression (SVR), à des résultats expérimentaux déviants ou mal réalisés. Dans le cas de la corrosion atmosphérique, on pourrait peut-être privilégier effectivement le dernier type d'algorithme, les Random Forest, les mesures en extérieur dans des environnements non-contrôlés étant par essence plus susceptibles de dévier.

L'approche du Machine Learning est une voie prometteuse pour les chercheurs en corrosion. Ce genre d'approche est amené à se développer rapidement dans les années à venir, la jeunesse de la littérature citée dans ces paragraphes en est témoin. La plus grande contribution du Machine Learning au domaine est sûrement la possibilité de créer des modèles multi-paramètres. La science des matériaux a toujours cherché à complexifier les modèles en y intégrant le plus de paramètres possibles. Le Machine Learning permet de passer un cap dans cette démarche.

5 Réalisation d'une database pour étudier la résistance des alliages Nickel à la corrosion

La base de données est l'élément central qui permet le fonctionnement d'un algorithme d'apprentissage. C'est en utilisant cette database que l'intelligence artificielle va apprendre, s'entraîner, puis faire des prédictions et les vérifier. Sa qualité va conditionner la pertinence du résultat donné par le programme qui va l'exploiter. En effet, l'algorithme effectuera toujours une prédiction lorsque cela lui est demandé. Cependant, si la qualité du set de données sur lequel il s'est entraîné (base de données ou dataset) est mauvaise, la prédiction a plus de chances d'être fausse.

Dès lors, l'étape de collecte et de sélection des données n'est pas anodine. Il est essentiel qu'un algorithme d'apprentissage automatisé soit utilisé pour répondre à une problématique unique et bien définie. Cela signifie que l'on ne peut se contenter de nourrir l'algorithme de toutes les données possibles. Une utilisation anarchique de variables d'entrée peut même se révéler contre-productive, en créant des rapprochements entre des données qui n'auraient pas lieu d'être.

Notre algorithme doit permettre de choisir le matériau le plus résistant à la corrosion par crevasse pour des conditions expérimentales données. Pour cela, nous avons décidé de donner en sortie du programme des valeurs permettant de caractériser cette résistance, pour chaque alliage choisi par l'utilisateur. En fonction des résultats de l'algorithme et de ses critères, ce dernier sera alors en mesure de choisir l'alliage qui lui conviendra le mieux.

Nous avons donc formulé la question à laquelle doit répondre l'algorithme : **pour un milieu donné, quelles sont les valeurs des paramètres caractérisant le comportement d'un alliage soumis à la corrosion par crevasse ?**

5.1 Sélection des paramètres de la base de données

Ainsi, en amont, il nous faut répondre à une question : quelles caractéristiques prendre en compte pour caractériser le comportement sous corrosion par crevasse ?

A partir de cette question, nous avons défini différents types de données :

- **Les paramètres de l'environnement**, qui vont avoir une influence sur l'ampleur du mécanisme de corrosion caverneuse,
- **La composition du matériau**, qui va conditionner sa capacité à résister à la corrosion,
- **Les indicateurs du comportement face à la corrosion**, qui permettent d'évaluer la résistance à la corrosion du matériau,
- **Les propriétés du matériau** telles que le module d'Young ou son prix, afin de viser la meilleure adéquation entre l'usage qui en est fait et sa résistance à la corrosion.

5.1.1 Paramètres d'entrée de la base de données

On s'intéresse aux paramètres qui vont influencer la résistance à la corrosion du matériau. Elle dépend à la fois de l'environnement et de la composition chimique du matériau.

Le mécanisme de corrosion caverneuse est principalement dû à la présence de certains éléments comme les ions halogénures. Ce sont ces éléments chimiques de petite taille qui vont venir fragiliser le film passif et provoquer la corrosion du matériau [70]. Ainsi on s'intéresse à la présence de ces espèces dans le milieu (par exemple Cl^- dans l'eau salée), mais aussi à la présence d'acides qui sont susceptibles de les libérer en milieu aqueux (HCl , HBr).

Au-delà de ces espèces, on s'intéresse à toutes les données que l'on peut avoir sur la composition du milieu. Par exemple, la présence en plus ou moins grande concentration d'oxygène va faciliter la repassivation [70], c'est à dire la reconstruction du film passif qui a été attaqué par la corrosion. Des ions positifs (sodium, potassium, fer) peuvent aussi attirer des chlorures et catalyser les mécanismes de corrosion localisée. Ainsi, même si le mécanisme de la corrosion par crevasse est principalement dû à la présence d'halogénures, d'autres éléments peuvent freiner ou accélérer la cinétique de corrosion.

Les conditions physiques du milieu ont aussi une influence sur les mécanismes de corrosion. La température a un impact important sur la cinétique. En effet, elle accélère les réactions quand elle augmente [70]. La vitesse de dégradation du matériau peut devenir critique lorsque la température est élevée.

Les contraintes auxquelles sont soumises le matériau sont à prendre en compte, car la possibilité de corrosion sous contraintes n'est pas négligeable lorsqu'il y a corrosion localisée. Des fissures peuvent s'ouvrir sous l'action conjuguée de la corrosion et de la contrainte, et provoquer une destruction rapide du matériau. Cependant, cet aspect n'a pas été développé, car nous n'avons pas récupéré de données concernant les possibilités d'un couplage entre corrosion par crevasse et contraintes.

Enfin, si le matériau est en contact avec un fluide en mouvement, la vitesse de celui-ci a de l'importance, car il peut y avoir érosion du matériau et formation de cavernes. Le fluide peut par ailleurs contribuer à un apport d'espèces oxydantes [70]. Ce paramètre intervient lors d'essais en eau de mer.

Les éléments d'addition vont permettre de limiter les effets de l'environnement sur le matériau. Certains éléments tels que le chrome, le molybdène ou l'azote sont connus pour renforcer la résistance à la corrosion localisée. Qu'en est-il des autres éléments d'alliage ? L'utilisation de l'intelligence artificielle va permettre de quantifier l'influence de ces éléments sur la résistance à la corrosion par crevasse. D'autres éléments peuvent avoir pour effet de stabiliser le film passif et de retarder la corrosion localisée. On s'intéresse donc à un maximum d'éléments d'addition, afin d'établir la contribution de ces éléments à la résistance à la corrosion de façon précise.

La microstructure de l'alliage peut affecter la résistance à la corrosion localisée [71]. Cependant, nous n'avons pas développé cet axe, car toutes les données que nous avons recueillies ne concernaient que le lien entre composition chimique et corrosion.

5.1.2 Paramètres de sortie de la base de données

Ces paramètres correspondent aux caractéristiques que vont avoir un matériau donné dans un certains milieu. On distingue des caractéristiques qui permettent d'évaluer la résistance à la corrosion et des caractéristiques reliées à l'usage qui va être fait du matériau.

Avec quels indicateurs peut-on quantifier la résistance à la corrosion ? Nous avons retenu assez naturellement la vitesse de corrosion. Il s'agit de l'indicateur le plus explicite concernant l'importance de la corrosion sur le matériau, car il permet d'évaluer sa durabilité face à la corrosion dans l'environnement. Nous nous intéressons aussi à la température critique de corrosion par crevasse (CCT). Il s'agit d'une grandeur utilisée pour quantifier la résistance à la corrosion par crevasse. Elle correspond à la température qui permet la formation d'une caverne de 0,025 mm de profondeur en 24h dans un environnement chloruré défini selon la norme ASTM G-48 [8]. La CCT de tous les matériaux étant évaluée dans les mêmes conditions, elle permet de classer les performances des alliages. Plus sa CCT sera élevée, et plus l'alliage sera résistant à la corrosion par crevasse.

Enfin, on peut évaluer la résistance à la corrosion localisée à travers le PREN. On considère qu'un PREN supérieur à 40 permet une bonne tenue à la corrosion. Le PREN n'apporte pas d'informations dans la mesure où il est calculé à partir de la composition du matériau. Cependant comme il s'agit d'un paramètre intrinsèque du matériau, il permet de vérifier le bon fonctionnement de l'IA. On peut le déterminer pour des matériaux qui ne font pas parti de la base de données à l'aide de l'algorithme, et ensuite le comparer à des données bibliographiques.

Enfin on s'intéresse aux propriétés qui conditionnent l'usage qui est fait du matériau.

Le prix du matériau est un critère important. En effet, un matériau très noble résistera bien à la corrosion dans un grand nombre de situations. Cependant ces matériaux ont un coût élevé. On cherche donc à déterminer des conditions limites à partir desquelles le matériau présente une résistance à la corrosion acceptable.

Le module d'Young est aussi à prendre en compte en fonction de l'environnement. En effet, sous contraintes, les effets de la corrosion peuvent être accentués en cas de fissuration.

Le potentiel de corrosion est intéressant pour avoir une représentation du comportement du matériau face à la corrosion généralisée. Il n'est toutefois pas particulièrement pertinent pour étudier la corrosion par crevasse. En effet, du fait de la forte concentration en espèces agressives dans les crevasses, le potentiel à partir duquel la corrosion s'y manifeste est bien inférieur au potentiel de

corrosion. On ne peut donc pas comparer la résistance à la corrosion par crevasse en comparant les potentiels de corrosion [70]. Ainsi, nous n'avons pas retenu ce critère comme indicateur de la résistance à la corrosion par crevasse.

5.2 Acquisition de données

L'acquisition de données s'est faite à partir de publications scientifiques sur la résistance de certains alliages à base nickel, ainsi qu'à partir de datasheets de fabricants d'alliages ou d'organismes de référence tels que Special Metals Corporation, Steek Tubes India ou le Nickel Institute [9, 72, 73, 74, 75, 76, 77, 78, 79, 80, 81, 82, 83, 84, 85, 86]. Les données contenues dans ces documents ont ensuite été reportées à la main dans notre base de données. La taille de la base de données est assez modeste pour un algorithme d'apprentissage, car elle a été limitée par le temps nécessaire pour son remplissage. Nous précisons également que les informations rentrées dans la base de données concerne des alliages base nickel conventionnels.

La vitesse de corrosion n'est pas une propriété intrinsèque du matériau. Elle dépend des conditions du milieu. Ainsi, sa mesure ne peut être séparée des conditions expérimentales. A chaque mesure correspond donc une entrée dans la base de données, qui contient la mesure pour un alliage donné, dans des conditions expérimentales données.

La réalisation de la base de données est passée par plusieurs étapes. On a commencé par réfléchir aux données nécessaires à la résolution du problème à partir d'ouvrages et de publications sur la corrosion par crevasse. Dans une seconde phase, nous avons recherché des sources permettant de se procurer ces données. Enfin, une petite phase de nettoyage de la base de données a permis de la compléter.

6 Programmation d'une IA pour aider au choix des matériaux

6.1 Réflexions préliminaires

Nous nous sommes ensuite employés à rédiger un programme nous permettant d'exploiter la base de données, le but étant de prédire le comportement à la corrosion d'un matériau de composition donnée. Pour cela, nous avons utilisé la librairie (collection de fichiers de code) d'intelligence artificielle *scikit-learn*, sur le langage de programmation Python. Nous nous sommes orientés vers ce module car il était grandement documenté, semblait accessible à l'auto-formation, et se basait sur nos quelques connaissances de la programmation Python.

6.1.1 Choix de l'approche

Comme nous l'avons vu au cours de notre étude bibliographique (section 4.2), nous avions à notre disposition plusieurs manières d'aborder notre programme (classification, régression, *Clustering*...). Afin d'y voir plus clair, nous avons utilisé l'arbre de décision proposé par le site *scikit-learn.org* [87], visible en figure 20.

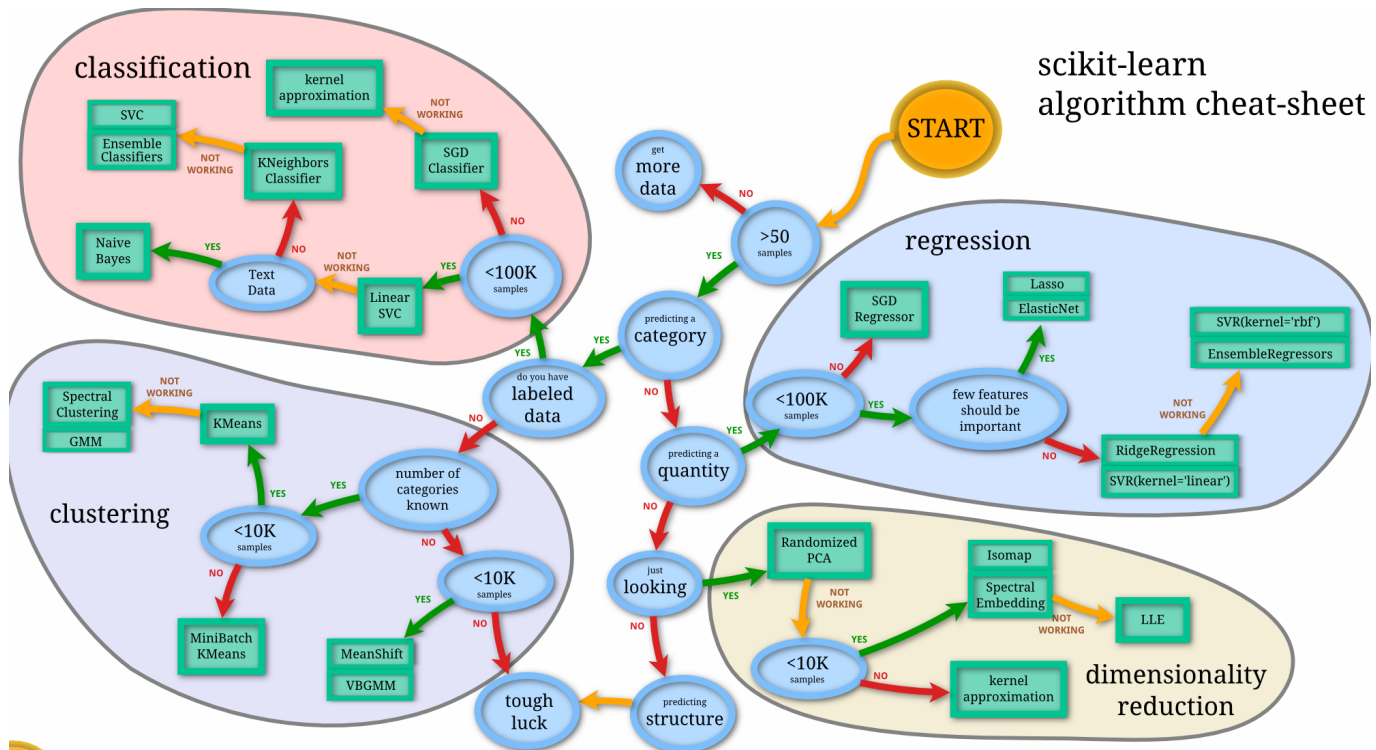


FIGURE 20 – Arbre de décision de *scikit-learn.org* [87]

D'une part, nous pouvons nous orienter du côté de la régression, puisque nous cherchons à prédire

des quantités (les valeurs de E, CCT, PREN...) sans uniquement les regarder (soit aller dans la réduction dimensionnelle). Nous pourrions aussi nous orienter vers la classification, mais pas vers le Clustering, puisque nous ne connaissons pas exactement le nombre de catégories.

Nous avons alors dû déterminer quelle approche choisir entre classification et régression. Nous avons résumé notre raisonnement dans le tableau 21 :



	Principe	En entrée	En sortie	Avantages	Inconvénients
Classification 	<i>"Sachant l'environnement, quel est le meilleur matériau ?"</i>	Paramètres de l'environnement	Le matériau entré dans la base de donnée ayant la meilleure performance de résistance à la corrosion	<ul style="list-style-type: none"> • Donne directement le meilleur matériau 	<ul style="list-style-type: none"> • Le programmeur doit effectuer un traitement des données à la main pour déterminer le meilleur matériau pour des conditions données • Pour comparer, nous sommes obligés d'avoir les mêmes conditions expérimentales • Ne donne que le premier résultat, sans prendre en compte d'autres critères
Regression 	<i>"Quelle résistance à la corrosion de chaque matériau dans un environnement donné"</i>	Paramètres de l'environnement + Composition des différents matériaux que l'on envisage	Pour chaque composition, les performances de résistance à la corrosion et autres paramètres (prix, E...)	<ul style="list-style-type: none"> • Peut s'adapter à n'importe quelle composition • + d'éléments pour faire son choix 	<ul style="list-style-type: none"> • Ne donne pas directement le meilleur matériau

FIGURE 21 – Approches et comparaison de la classification et la régression

Nous avons choisi la régression, car elle sera moins exigeante au niveau des données à récupérer. En effet, la classification suppose un traitement des données préalables pour déterminer le "meilleur" matériau. Or, pour les comparer, nous devons avoir exactement les mêmes conditions expérimentales d'un alliage à l'autre. Par ailleurs, choisir la régression nous permettra d'obtenir les performances de chaque alliage, pour adapter son choix selon ses critères (résistance mécanique, prix...).

6.1.2 Choix de l'algorithme

Une fois l'approche de la régression choisie, il nous a fallu décider quel algorithme utiliser. Nous avons déterminé plusieurs critères pour choisir notre algorithme :

- Une bonne performance prédictive
- Plus de variables que d'observations : Chaque observation (par exemple, le PREN) dépend de plusieurs variables (comme la composition en Cr, Mo, Ni), que nous appelons aussi *features* ou paramètres. Or, comme vu précédemment, la database comprend de très nombreux paramètres (environnement, composition...), qui correspondent en somme à la tête des colonnes de la database.

- Adaptation à des situations non linéaires : Rien n'indique que les comportements étudiés suivent une loi linéaire.
- Ne nécessite pas d'expertise avancée : En effet, n'étant pas informaticiens de formation, nous avons dû nous auto-former.
- Une bonne intelligibilité explicative : Nous souhaitons comprendre au mieux le programme, afin de pouvoir porter un regard critique sur les résultats obtenus, et tirer le plus d'informations possibles. Ce critère est cependant le moins privilégié pour nous.

Pour nous aider dans notre choix, nous nous sommes inspirés du tableau fourni par *XLSTAT*, en figure 5 [88].

Algorithme	Fonctionne avec plus de variables que d'observations	S'adapte à des situations non linéaires	Intelligibilité explicative	Remarques
Régression linéaire	Non	-	+++	
Régression pénalisée (<i>Ridge</i> , <i>Lasso</i> , <i>ElasticNet</i>)	Oui	-	++	
Régression quantile	Oui	-	+	
Modèle Additif Généralisé (GAM)	Non	++	+	
Régression avec Moindres Carrés Partiels (PLS)	Oui	-	+	Quand peu d'observations et beaucoup de variables
Régression sur les Composantes Principales (PCR)	Oui	-	+	
K Plus Proches Voisins (KNN)	Oui	++	-	
Arbres de Régression (C&RT, CHAID)	Oui	++	++	Ramifications binaires ou multiples à chaque noeud
Forêts Aléatoires de Régression (Random Forests)	Oui	++	+	Meilleure performance prédictive que celle des arbres de régression
Réseaux de Neurones Artificiels (ANN)	Oui	++	-	Nécessite expertise avancée

TABLE 5 – Comparaison d'algorithmes de machine learning supervisé utilisant la régression

Le programme Random Forest est celui qui correspond le mieux à nos attentes. Ce choix est

conforté par notre étude en partie 4, qui a montré l'utilisation de ce programme pour le choix des matériaux et la corrosion, ainsi que sa bonne fiabilité. Faire un Réseau de Neurones aurait aussi été intéressant, car cela aurait permis d'obtenir un comportement global, sans faire tourner le programme pour chaque paramètre de sortie. Cependant, le niveau d'expertise demandé était trop important.

6.2 Présentation du programme réalisé

Nous avons ensuite réalisé un programme exploitant un algorithme Random Forest. Pour cela, nous nous sommes aidés d'un script de Marie-Jeanne Vieille, disponible sur le site *Lovely Analytics* [89]. Au cours de cette partie, nous allons expliquer les points essentiels de notre programme. Le but n'est pas d'en fournir une explication exhaustive, mais de mettre en lumière les éléments intéressants dans le cadre de notre étude.

6.2.1 Exploration et visualisation des données

- Analyse de la quantité de données avec *pandas-profiling* :

Nous avons entré la base de données détaillée précédemment dans le programme. Afin de porter un regard critique sur nos entrées, nous utilisons le module *pandas-profiling*, qui effectue une analyse de données. En figure 22, nous avons par exemple des données intéressantes sur les alliages que la base de données contient. Nous avons donc entré 34 alliages différents. Parmi les plus présents, nous retrouvons des alliages assez connus et répandus [78], ce qui est positif car ce sont des alliages qui ont une forte probabilité d'être entrés directement dans la base de données. Ces alliages sont surtout des alliages Ni-Cr-Mo : 59 (ou N06059), C-276, C-2000 et 686, ce qui peut potentiellement poser problème pour la diversité des données de référence.



FIGURE 22 – Exemple d'analyse des noms d'alliage avec *pandas-profiling*

D'autres données statistiques intéressantes à souligner sont la valeur moyenne et le pourcentage

de variation des données. Par exemple, considérons le cas de la CCT (figure 23). 5.1% des valeurs sont distinctes, ce qui montre que de nombreux alliages ont la même CCT. Par ailleurs, la moyenne est de 54°C, ce qui est élevé [90], et correspond bien au fait que les alliages Nickels sont résistants à la corrosion par crevasse.

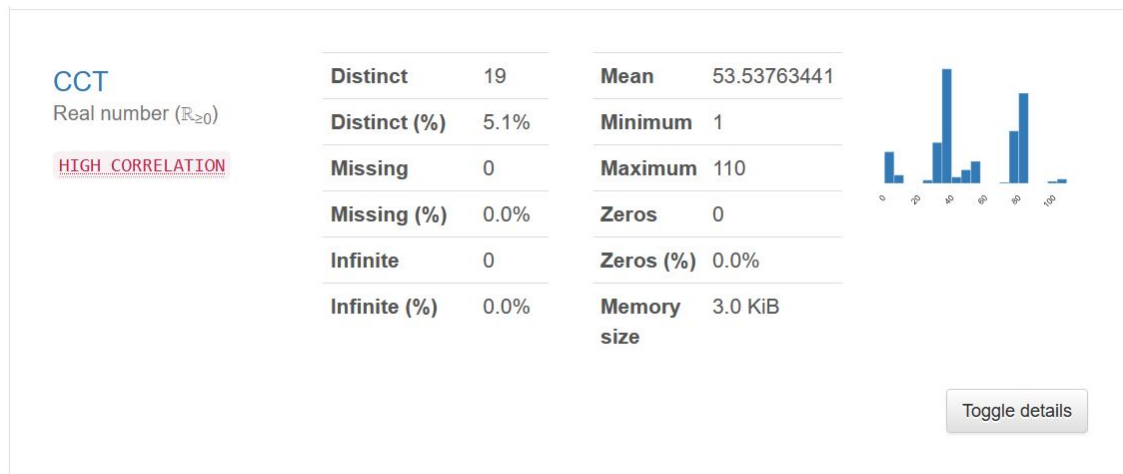


FIGURE 23 – Exemple d’analyse de la CCT avec *pandas-profiling*

Les variables hautement corrélées sont aussi signalées par *pandas-profiling*, comme nous pouvons le voir pour le cas du Nom d’Alliage. Il peut être intéressant de supprimer ces données, car elles peuvent perturber les prédictions. Nous nous y sommes alors intéressé plus en détails.

- Corrélations et choix des données

La corrélation entre les grandeurs peut impacter notre modélisation. En effet, si deux variables sont corrélées (coefficient de corrélation proche de 1 ou -1), elles dépendent l’une de l’autre, et suivent la même loi. Cette loi risque alors de peser deux fois au moment de l’établissement du modèle par le programme. Par ailleurs, une corrélation positive entre deux indicateurs a et b indique que si a augmente, b augmente aussi. Nous avons affiché une table des corrélations pour les paramètres d’entrée, afin d’en avoir une meilleure vision (figure 24).

Nous ne trouvons pas de corrélation particulièrement forte, il n’y a aucun coefficient dont la valeur absolue est supérieure à 0.9 par exemple. La valeur absolue du coefficient est supérieure à 0.7 pour trois relations impliquant la composition de l’alliage : W/Cu, Mo/Ni, Mn/Ni. On peut en effet parfois retrouver ces éléments de composition dans des proportions presque similaires pour plusieurs alliages, ce qui peut expliquer la corrélation détectée. Par ailleurs, nous pouvons souligner que ces éléments sont alphagènes ou gammagènes, c’est à dire qu’ils favorisent respectivement la forme ferritique (W, Mo) et austénitique (Mn, Ni, Cu) de l’acier [91]. Ainsi, le respect d’une certaine proportionnalité entre les compositions, d’un alliage à l’autre, peut correspondre à une volonté de garder un même équilibre entre la forme austénitique et ferritique. Or, il est évident que ces paramètres, même s’ils peuvent

s'influencer, ne vont pas suivre une même loi. Il n'y a donc pas de problème lié aux corrélations dans notre tableau de données.




FIGURE 24 – Corrélations obtenues pour les données sélectionnées

Nous nous sommes aussi intéressés aux corrélations entre les valeurs de sortie. Nous constatons ainsi une forte corrélation entre le PREN et la CCT (0.91). Ceci peut s'avérer intéressant, car, si ces deux valeurs sont reliées, avoir une information sur l'une d'entre elles peut nous permettre de déduire

l'autre. Cette corrélation a déjà été prouvée dans la bibliographie. En effet, d'une part, la CCT est en moyenne inférieure à la CPT de 15°C à 20°C [92]. D'autre part, la corrélation entre CPT et PREN a été montrée empiriquement par des chercheurs [93]. La forte corrélation entre PREN et CCT n'est donc pas étonnante.

Une fois les données vérifiées, nous pouvons les soumettre à notre intelligence artificielle.

6.2.2 Utilisation de l'intelligence artificielle

Nous avons ensuite entraîné une intelligence artificielle type Random Forest sur notre dataset. Pour cela, nous importons *RandomForestRegressor* depuis la bibliothèque de Machine Learning *scikit-learn*, en créant deux groupes :

- *Train (75% des données)* : Pour l'apprentissage et la modélisation d'un comportement
- *Test (25% des données)* : Pour vérifier que le programme ait bien "appris"

A l'issu de l'apprentissage, nous regardons l'erreur moyenne et le pourcentage d'erreurs obtenus à l'issu de la phase de test (figure 25).

```
Mean Absolute Error for CCT: 1.5249462366
Mean Absolute Percentage Error for CCT: 18.4468680662 %.
Mean Absolute Error for PREN: 0.6456774194
Mean Absolute Percentage Error for PREN: 7.8208500831 %.
Mean Absolute Error for E: 0.5705376344
Mean Absolute Percentage Error for E: 0.3169016669 %.
Mean Absolute Error for Vcorr: 2293.199177574
Mean Absolute Percentage Error for Vcorr: 22119.2866125779 %.
Mean Absolute Error for Prix: 0.7953339785
Mean Absolute Percentage Error for Prix: 2.8687384439 %.
```

FIGURE 25 – Erreurs obtenues lors du test

Nous pouvons constater que les erreurs sont faibles pour le PREN, E, et le prix, mais un peu plus fortes pour la CCT. En effet, cette dernière dépend des conditions d'expérimentation au cours de laquelle elle a été déterminée, et peut légèrement varier selon les bibliographies. Il est donc plus difficile de déterminer la CCT avec certitude, et cela nécessitera plus de données. Ainsi, pour ces quatre grandeurs, les résultats sont satisfaisants, et nous pouvons continuer à travailler avec la base de données établie.

Cependant, nous trouvons des erreurs beaucoup trop fortes pour la vitesse de corrosion. En effet, la vitesse de corrosion peut varier en fonction de très nombreuses variables, notamment expérimentales. Il nous faudrait donc une base de données beaucoup plus complète que ce que nous avons à notre disposition pour avoir un meilleur aperçu de V_{corr} . L'hypothèse d'un manque de données est renforcée par le fait que nous avons obtenu un pourcentage d'erreur 3 fois plus important lorsque nous ne prenons que la moitié des données.

6.2.3 Paramètres d'influence

Le module de Random Forest utilisé nous permet aussi d'étudier l'importance des paramètres sur la grandeur de sortie. Nous pouvons ainsi constater quelques éléments notables.

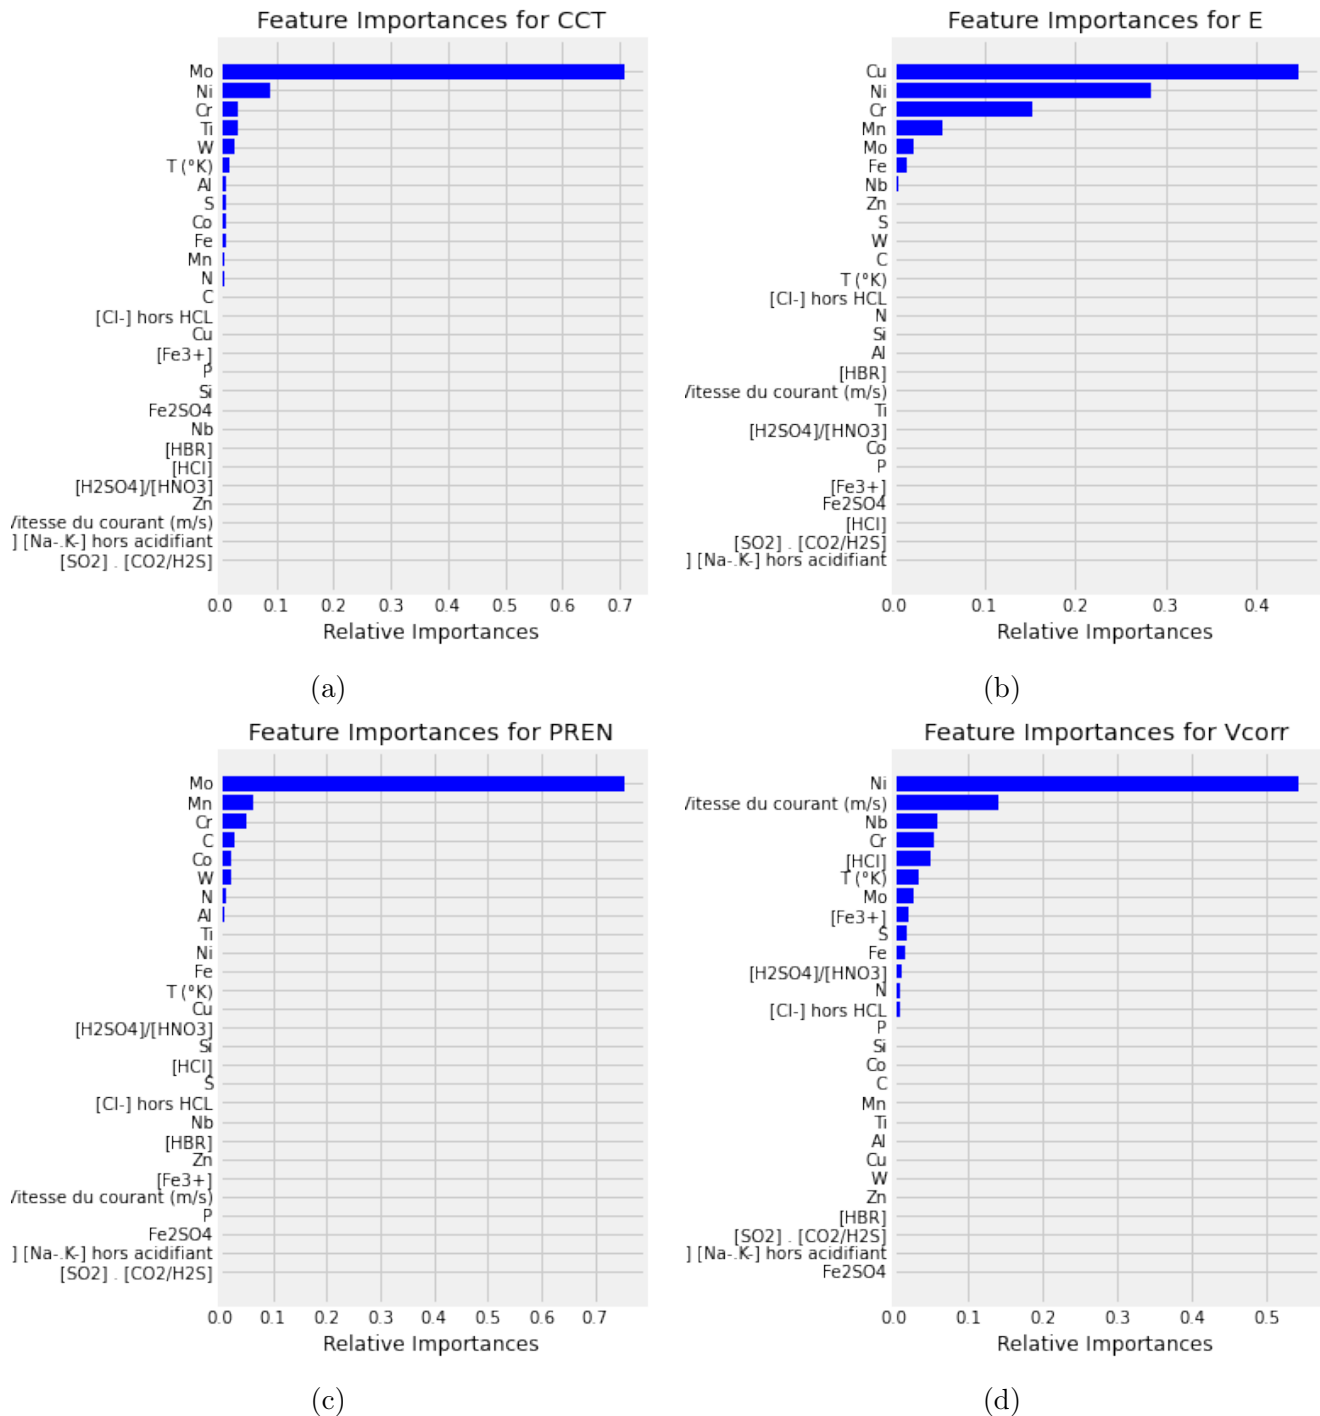


FIGURE 26 – Paramètres d'influence des différentes grandeurs de sortie




FIGURE 27 – Paramètres influençant le prix

Nous obtenons ainsi un grand nombre d'informations, que nous n'allons pas détailler ici de manière exhaustive. Cependant, quelques résultats ont particulièrement attiré notre attention.

Notamment, concernant le PREN et la CCT (qui sont corrélés), l'influence du Mo, du Cr et du W se justifie par le rôle important que jouent ces éléments dans le calcul du PREN : $\text{PREN} = \%Cr + 3.3(\%Mo + 0.5\%W) + 16\%N$. La faible influence du N s'explique par la faible présence de cet élément d'alliage dans nos bases de données.

Par ailleurs, nous pouvons voir l'impact d'éléments durcissants [94] tels que Cr, Ni et Mo sur le module d'Young du matériau.

Concernant le prix, même si la valeur de certains métaux tel que le titane sont montrées, les résultats sont encore trop influencés par la quantité d'éléments d'alliage utilisés dans notre base de données. Les prix sont en effet difficilement estimables, les lois des marchés n'étant pas toujours prévisibles, même pour une intelligence artificielle.

Pour conclure, nous pouvons voir que les conditions expérimentales n'impactent que la vitesse de corrosion. Cela est logique, car V_{corr} est la seule grandeur de sortie non intrinsèque au matériau.

6.2.4 Utilisation du programme

Nous pouvons maintenant passer à l'interface utilisateur. Une fois le programme lancé, une fenêtre s'affiche. L'utilisateur n'a plus qu'à y entrer les différents paramètres, ainsi qu'à sélectionner les grandeurs qu'il souhaite voir en sortie. Ces grandeurs s'affichent après validation (figure 28).

Quelles conditions expérimentales ?

Ni	14	N	0
Cr	18	Zn	0
Fe	62	T (°K)	0
C	0.03	[HCl]	0
Cu	0	[Cl-] hors HCL	0
Ti	0	[Fe3+]	0
W	0	[H2SO4]/[HNO3]	0
Al	0	[HBR]	0
Nb	0	[SO2] . [CO2/H2S]	0
Co	0	Fe2SO4	0
S	0.03	[ions métalliques] [Na-.K-] hors acidifiant	0
P	0.04	Vitesse du courant (m/s)	0
Mn	2		
Si	0.75		
Mo	3		

Que voulez-vous en sortie?

☒ CCT (°K) CCT : 10
 ☒ PREN PREN : 24
 ☒ E (GPa) E : 200

☐ Vcorr (micromètres/an)
 ☐ Prix (US\$/kg)

Allons-y

FIGURE 28 – Obtention des grandeurs désirées

6.3 Vérification de l'algorithme

Nous avons voulu vérifier le bien-fondé des valeurs en sortie de notre algorithme. Pour cela, nous avons entré dans le programme des alliages inconnus de notre database, et avons comparé les valeurs obtenues à celles trouvées dans la bibliographie [72, 92, 95]. Parmi les 5 grandeurs de sorties possibles, nous n'avons choisi d'étudier que le module d'élasticité, le PREN et la CCT. En effet, les erreurs sur la vitesse de corrosion étant élevées, et le prix étant fortement influencé par nos données, cela ne nous a pas semblé pertinent de nous pencher sur ces grandeurs. Nous réalisons ainsi la Table 6, en triant les alliages par ordre décroissant de composition en Nickel.

Alliage		E (GPa)		PREN		CCT (°C)	
Nom	% Ni	Biblio	Programme	Biblio	Programme	Biblio	Programme
904L	25	190	200	35	35	20	22
317L	15	200	201	29	24	0	11
316L	13	193	200	25	24	10	10
Ferralium	6.5	199	150	40	33	25	28
Acier Duplex 2205	5.6	193	152	31	30	32	26
2304	4	190	153	24	32	20	28
LDX 2101	1.7	200	151	26	29	10	26

TABLE 6 – Comparaison de nos résultats avec la théorie

Nous pouvons voir que, dans l'ensemble, les résultats obtenus sont assez proches de la bibliographie. Cela est particulièrement vrai pour les alliages avec plus de 10% de nickel. Nous pouvons remarquer que, parmi ces derniers, le 317L a une CCT surestimée. Cela peut s'expliquer par le fait que nous avons plutôt des alliages de forte CCT dans notre database. Le programme aura donc moins tendance à attribuer une CCT proche de 0.

Nous avons aussi entré moins d'alliages à faible teneur en nickel, ce qui explique les écarts plus importants à la mesure lorsque le pourcentage en nickel diminue. Pour les aciers plus faiblement alliés, nous pouvons notamment remarquer une sous-estimation du module d'élasticité, qui est aussi dû à un manque de variété de nos valeurs.

Pour conclure, les résultats de notre programme sont satisfaisants. Cependant, par le manque de temps et de moyens à notre disposition, nous n'avons pas encore entré assez de données pour avoir des valeurs correctes pour tous les alliages nickel. Nos résultats restent donc encore fortement dépendants des valeurs d'entrée.

6.4 Pistes d'amélioration

Ce programme s'avère assez efficace, mais il est possible de l'améliorer sur plusieurs points.

A plusieurs reprises, la base de données a été limitante pour obtenir des résultats exacts. En effet, avec les moyens et le temps à notre disposition, nous ne pouvons pas prétendre avoir une database exhaustive. De plus, certains paramètres influençant la corrosion par crevasse dans l'eau de mer n'y sont pas mentionnés, faute de données (organismes marins, ...). La base de données peut donc être renforcée et complétée.

Comme nous l'avons déjà expliqué précédemment, nous aurions pu utiliser un Réseau de Neurones, plus complexe, mais sans doute plus pertinent. Il serait donc intéressant de voir les performances d'un tel programme, et de vérifier s'il est effectivement plus efficace.

L'interface utilisée ne s'obtient qu'en utilisant le programme Python. Le développement d'une interface au sein d'une application ou d'un site web serait sans doute plus aisé et agréable, et éviterait des manipulations malencontreuses.

7 Conclusion et remerciements

Comme rappelé en introduction de ce rapport, les objectifs visés par notre groupe sont multiples.

Tout d’abord, notre objectif était de comprendre et de restituer les problématiques techniques et industrielles dont est issu notre sujet de Projet Collectif. Ainsi, nous avons pu présenter la problématique de la corrosion, en se focalisant sur deux types de corrosion localisée : la corrosion caverneuse et la corrosion par piqûres. La compréhension de ces deux mécanismes est essentielle dans l’industrie pétrolière off-shore, car elle conditionne l’utilisation de nuances d’alliages spécifiques. Par ailleurs, notre deuxième partie s’est concentrée sur la présentation des alliages à base nickel, principaux candidats pour les équipements pétroliers. Nous avons pu présenter plusieurs types d’alliages utilisant du nickel dont entre autre : les alliages conventionnels, les alliages à haute entropie et les verres métalliques.

Dans un second temps, nous nous sommes concentrés sur l’intelligence artificielle. L’idée étant ici de présenter son principe, ses enjeux et ses algorithmes phares. Puis, nous avons poursuivi par un état de l’art de son utilisation dans le monde scientifique, spécifiquement dans le milieu des sciences des matériaux et évidemment de la corrosion. L’idée étant ici de montrer à quel point l’utilisation de l’intelligence artificielle est variée dans ces domaines. Nous avons d’ailleurs présenté plusieurs problèmes de corrosion dont l’utilisation de l’IA pourrait offrir de nouvelles perspectives.

Pour terminer, les deux dernières parties ont fait office d’expérimentation. En effet, pour compléter notre démarche d’état de l’art, nous avons pris le parti d’expérimenter la création d’une base de données matériaux en corrosion et la création d’un programme utilisant un algorithme d’intelligence artificielle, le Random Forest (RF). Cette expérimentation nous a permis de rendre compte de problématiques pratiques à la résolution d’un problème de corrosion par l’IA. Ainsi, nous avons à la fois abordé des problématiques concernant le remplissage de la base de données, et concernant le choix et l’utilisation de l’algorithme.

Ce rapport n’a pas la prétention d’être totalement exhaustif. Cependant, en tant qu’auteurs, nous espérons avoir résumé, et surtout vulgarisé la plupart des points que nous avons abordés pour que le lecteur ait une vision d’ensemble des problèmes ayant abouti sur notre projet. Nous espérons aussi avoir donné aux lecteurs de ce rapport des pistes pour une future utilisation de l’intelligence artificielle dans leur domaine d’expertise, ou plus précisément pour la corrosion.

Nous tenons à remercier Industeel pour son partenariat avec l’INSA Lyon et son implication dans notre formation. Nous remercions Madame Caroline Bessac, pour son module de management, qui nous a permis d’évoluer dans notre fonctionnement de groupe. Nous remercions Madame Aude Tallaron et le personnel de la BMC pour son aide à la création de notre bibliographie et sa formation à Zotero. Nous remercions bien sûr Monsieur Hugo Klinklin pour les travaux qu’il nous a transmis qui nous ont été d’une très grande aide. Enfin, nous remercions Monsieur Benoit Ter-Ovanessian, pour l’idée du projet, ses conseils et son encadrement avisé.

8 Bibliographie

Pour citer ce rapport : GINER L, GRENIER M, GUÉNÉGUAN M, GUÉRIN C, HOESCH A, HOU Y, et TRILLAT A. Intelligence artificielle et Corrosion. INSA Lyon - Département Science et Génie des Matériaux ; 2021 avr p. 59.

Références

1. [S.N]. Sous l'effet de la corrosion Une plate-forme pétrolière s'effondre en mer Caspienne. Le Monde. 27 Août 1987. Accessible sur: https://www.lemonde.fr/archives/article/1987/08/27/sous-l-effet-de-la-corrosion-une-plate-forme-petroliere-s-effondre-en-mer-caspienne_4044886_1819218.html [Consulté le: 6 Avril 2021]
2. MICHEL P. L'industrie pétrolière mobilisée contre la corrosion. Industrie & technologies. 1 Avril 2016. Accessible sur: [/article/1-industrie-petroliere-mobilisee-contre-la-corrosion.43479](#) [Consulté le: 6 Avril 2021]
3. KLINKLIN H. Synthèse bibliographique - Corrosion caverneuse des alliages à base nickel. Indus-teel, 15 Décembre 2020. [Consulté le: 27 Avril 2021]
4. GROSGOGEAT B et COLON P. La Corrosion. Université Médicale Virtuelle Francophone, 2009. Accessible sur: <http://campus.cerimes.fr/odontologie/enseignement/chap6/site/html/cours.pdf> [Consulté le: 23 Février 2021]
5. MINISTÈRE DE LA TRANSITION ÉCOLOGIQUE. Qu'est ce que la corrosion ? 1 Août 2005. Accessible sur: <http://www.viabilite-hivernale.developpement-durable.gouv.fr/qu-est-ce-que-la-corrosion-a4339.html> [Consulté le: 23 Février 2021]
6. BERANGER G et TALBOT J. CORROSION. *Encyclopædia Universalis*. Encyclopædia Universalis. Accessible sur: <http://www.universalis-edu.com/docelec/insa-lyon.fr/encyclopedie/corrosion/> [Consulté le: 23 Février 2021]
7. LABORATOIRE MATEIS-CORRIS. Corrosion par piqûres. Le livre Multimedia de la corrosion. Accessible sur: https://www.cdcorrosion.com/mode_corrosion/corrosion_piqure.htm [Consulté le: 23 Avril 2021]
8. G01 COMMITTEE. Test Methods for Pitting and Crevice Corrosion Resistance of Stainless Steels and Related Alloys by Use of Ferric Chloride Solution. ASTM International. DOI : 10.1520/G0048-11R20E01. Accessible sur: <http://www.astm.org/cgi-bin/resolver.cgi?G48-11R20E1> [Consulté le: 29 Avril 2021]

9. HOULLE P. Résistance à la corrosion aqueuse des alliages de nickel. *Techniques de l'Ingénieur*. Editions T.I. 10 Juin 2015. Accessible sur: <https://www-techniques-ingenieur-fr.docelec.insa-lyon.fr/base-documentaire/42357210-metaux-et-alliages-non-ferreux/download/cor312/resistance-a-la-corrosion-aqueuse-des-alliages-de-nickel.html> [Consulté le: 6 Février 2021]
10. LABORATOIRE MATEIS-CORRIS. Corrosion Caverneuse. Le livre Multimedia de la corrosion. Accessible sur: https://www.cdcorrosion.com/mode_corrosion/corrosion_caverneuse.htm [Consulté le: 23 Février 2021]
11. KIM YP. Etude de la corrosion caverneuse d'un acier inoxydable austénitique : utilisation conjointe de l'émission acoustique et des techniques électrochimiques. Thèse de doct. France : INSA Lyon, 2003. 167 p.
12. GRILLIAT J, PIRE B, RABINOVITCH M et SALBAING J. NICKEL. *Encyclopædia Universalis*. Encyclopædia Universalis. Accessible sur: <http://www.universalis-edu.com.docelec.insa-lyon.fr/encyclopedie/nickel/> [Consulté le: 8 Février 2021]
13. [S.N]. Tableau périodique des éléments. *Wikipédia*. 28 Avril 2021. Accessible sur: https://fr.wikipedia.org/w/index.php?title=Tableau_p%C3%A9riodique_des_%C3%A9l%C3%A9ments&oldid=182377009 [Consulté le: 29 Avril 2021]
14. EQUIPE FUTURA SCIENCES. Nickel. Futura Sciences. Accessible sur: <https://www.futura-sciences.com/sciences/definitions/chimie-nickel-14795/> [Consulté le: 24 Mars 2021]
15. MGIMPEL et WHISKYKOKA. Nickel. *Wikipédia*. 24 Janvier 2021. Accessible sur: <https://fr.wikipedia.org/w/index.php?title=Nickel&oldid=179144952> [Consulté le: 10 Février 2021]
16. COUDERCHON G. Alliages fer-nickel et fer-cobalt - Propriétés magnétiques. *Techniques de l'Ingénieur*. Editions T.I. 10 Juin 1994. Accessible sur: <https://www-techniques-ingenieur-fr.docelec.insa-lyon.fr/base-documentaire/archives-th12/archives-convertisseurs-et-machines-electriques-tiadb/archive-1/alliages-fer-nickel-et-fer-cobalt-d2130/caracteristiques-generales-des-alliages-feni-d2130niv10003.html> [Consulté le: 10 Avril 2021]
17. GOUDET JL. Un verre plus résistant que l'acier. Futura Sciences. 17 Janvier 2011. Accessible sur: <https://www.futura-sciences.com/sciences/actualites/physique-verre-plus-resistant-acier-27246/> [Consulté le: 15 Mars 2021]
18. TOMEK.STA et NERFLES. Alliage à haute entropie. *Wikipédia*. 11 Mars 2019. Accessible sur: https://fr.wikipedia.org/w/index.php?title=Alliage_%C3%A0_haute_entropie&oldid=181982943 [Consulté le: 28 Avril 2021]
19. HAIRY P. Les nouveaux alliages à hautes performances. MetalBlog. 2 Décembre 2019. Accessible sur: <https://metalblog.ctif.com/2019/12/02/les-nouveaux-alliages/> [Consulté le: 5 Avril 2021]

20. LAURENT-BROCQ M et COUZINIÉ JP. Alliages multi-composants à haute entropie - Concepts, microstructures et propriétés mécaniques. *Techniques de l'Ingénieur*. Editions T.I. 10 Décembre 2017. Accessible sur: <https://www-techniques-ingenieur-fr.docelec.insa-lyon.fr/base-documentaire/innovation-th10/innovations-en-materiaux-avances-42186210/alliages-multi-composants-a-haute-entropie-re269/> [Consulté le: 10 Avril 2021]
21. CHAMPION Y et BLÉTRY M. Propriétés mécaniques des verres métalliques. *Techniques de l'Ingénieur*. Editions T.I. 10 Octobre 2009. Accessible sur: <https://www-techniques-ingenieur-fr.docelec.insa-lyon.fr/base-documentaire/42535210-materiaux-a-proprietes-mecaniques/download/n2720/proprietes-mecaniques-des-verres-metalliques.html> [Consulté le: 15 Mars 2021]
22. ORVEILLON G. Verres métalliques : conception, synthèse et caractérisation des propriétés magnétiques et de transport. Thèse de doct. Université Sciences et Technologies - Bordeaux I, 2008. 163 p. [Consulté le: 6 Avril 2021]
23. LKALLOY. Classification des alliages à base de nickel résistant à la corrosion. LKALLOY. 15 Août 2019. Accessible sur: <https://lkalloy.com/fr/classification-of-corrosion-resisting-nickel-based-alloys/> [Consulté le: 24 Mars 2021]
24. CONCEPT METAL. Alliages de Nickel - Concept Métal. Concept Metal. Accessible sur: <https://www.conceptmetal.eu/alliages-de-nickel/> [Consulté le: 6 Avril 2021]
25. CARLIER SA. Fiche technique 59. Accessible sur: <http://www.carlier.cc/fiche/42.html> [Consulté le: 5 Avril 2021]
26. GANASCIA JG. INTELLIGENCE ARTIFICIELLE (IA). *Encyclopædia Universalis*. Encyclopædia Universalis. Accessible sur: <http://www.universalis-edu.com.docelec.insa-lyon.fr/encyclopedia/intelligence-artificielle-ia/> [Consulté le: 28 Janvier 2021]
27. PASTRE D. L'intelligence artificielle Définition- Généralités - Historique - Domaines. Février 2000. Accessible sur: <https://www.normalesup.org/~pastre/IA.pdf> [Consulté le: 25 Février 2021]
28. LAURIÈRE JL. Intelligence artificielle, Résolution de problèmes par l'Homme et la machine. T. 1. Paris : Editions Eyrolles, 1986. 475 p. [Consulté le: 26 Février 2021]
29. EQUIPE ROBANK HOOD. L'histoire de l'Intelligence Artificielle. Robank Hood. 23 Août 2019. Accessible sur: <https://robankhood.com/histoire-intelligence-artificielle/> [Consulté le: 28 Mars 2021]
30. AMONTSOURIS et PIERRE.LESCANNE. Lisp. *Wikipédia*. 15 Mars 2021. Accessible sur: <https://fr.wikipedia.org/w/index.php?title=Lisp&oldid=180890253> [Consulté le: 21 Avril 2021]

31. COMITÉ AD HOC SUR L'INTELLIGENCE ARTIFICIELLE. Histoire de l'intelligence artificielle. Conseil de l'Europe. Accessible sur: <https://www.coe.int/fr/web/artificial-intelligence/history-of-ai> [Consulté le: 20 Mars 2021]
32. COMPUTER SCIENTISTS. Intelligence Artificielle VS Machine Learning VS Deep Learning - Les différences entre ces termes. 10 Octobre 2018. Accessible sur: <https://www.youtube.com/watch?v=Sf0oRsUj9kQ> [Consulté le: 24 Mars 2021]
33. COLLET S. L'Intelligence Artificielle dans les Jeux Vidéo. Saagie. 2 Octobre 2018. Accessible sur: <https://www.saagie.com/fr/blog/blog-1-intelligence-artificielle-dans-les-jeux-video/> [Consulté le: 29 Avril 2021]
34. EQUIPE MATLAB. Introduction to Deep Learning : Machine Learning vs. Deep Learning. 4 Avril 2017. Accessible sur: <https://www.youtube.com/watch?v=-SgkLEuhfbg> [Consulté le: 24 Mars 2021]
35. GANASCIA JG. APPRENTISSAGE PROFOND ou DEEP LEARNING. *Encyclopædia Universalis*. Encyclopædia Universalis. Accessible sur: [http://www.universalis-edu.com/docelec.insa-lyon.fr/encyclopedie/apprentissage-profond-deep-learning/](http://www.universalis-edu.com/docelec/insa-lyon.fr/encyclopedie/apprentissage-profond-deep-learning/) [Consulté le: 28 Janvier 2021]
36. OUVRAGE COLLECTIF. Réseau de neurones. Data Analytics Post. Accessible sur: <https://dataanalyticspost.com/Lexique/reseau-de-neurones/> [Consulté le: 8 Avril 2021]
37. SRIVASTAVA T. How does Artificial Neural Network (ANN) algorithm work ? Simplified! Analytics Vidhya. 20 Octobre 2014. Accessible sur: <https://www.analyticsvidhya.com/blog/2014/10/ann-work-simplified/> [Consulté le: 5 Mars 2021]
38. SHEETAL S. Artificial Neural Network (ANN) in Machine Learning - Data Science Central. Data Science Central. 8 Août 2017. Accessible sur: <https://www.datasciencecentral.com/profiles/blogs/artificial-neural-network-ann-in-machine-learning> [Consulté le: 5 Mars 2021]
39. SINGH A. Support Vector Regression (SVR) Model : A Regression-Based Machine Learning Approach. Medium. 7 Mars 2021. Accessible sur: <https://medium.com/analytics-vidhya/support-vector-regression-svr-model-a-regression-based-machine-learning-approach-f4641670c5bb> [Consulté le: 12 Mars 2021]
40. SHIRAZI AZ et MOHAMMADI Z. A hybrid intelligent model combining ANN and imperialist competitive algorithm for prediction of corrosion rate in 3C steel under seawater environment. *Neural Computing and Applications*. 1 Novembre 2017; 28:3455-64. DOI : 10.1007/s00521-016-2251-6. Accessible sur: <https://doi.org/10.1007/s00521-016-2251-6> [Consulté le: 5 Mars 2021]

41. ÉQUIPE DATA SCIENCE. Algorithme N°2 - Comprendre comment fonctionne un random forest en 5 min. Ysance. 19 Juin 2020. Accessible sur: <https://blog.ysance.com/algorithme-n2-comprendre-comment-fonctionne-un-random-forest-en-5-min> [Consulté le: 8 Avril 2021]
42. HIKE395 et 3MTA3. Random forest. *Wikipedia*. 2 Mars 2021. Accessible sur: https://en.wikipedia.org/w/index.php?title=Random_forest&oldid=1009909609 [Consulté le: 5 Mars 2021]
43. SATYAVIR. Les nouveaux matériaux : quand l'IA ouvre des horizons de découvertes exponentielles. Courant Constructif. 13 Août 2019. Accessible sur: <https://courantconstructif.com/les-nouveaux-materiaux-quand-lia-ouvre-des-horizons-de-decouvertes-exponentielles/> [Consulté le: 26 Février 2021]
44. ROWENHORST DJ, NGUYEN L, MURPHY-LEONARD AD et FONDA RW. Characterization of Microstructure in Additively Manufactured 316L using Automated Serial Sectioning. *Current Opinion in Solid State and Materials Science*. 1 Juin 2020; 24:9. DOI : 10.1016/j.cossms.2020.100819. Accessible sur: <https://www.sciencedirect.com/science/article/pii/S1359028620300176> [Consulté le: 26 Février 2021]
45. SADOK A. Formulation des matériaux alternatifs par des approches d'intelligence artificielle. 20 Octobre 2016. [Consulté le: 3 Février 2021]
46. BISWAS A. Applications of Artificial Intelligence in Materials Science. AZoM.com. 30 Mars 2020. Accessible sur: <https://www.azom.com/article.aspx?ArticleID=19155> [Consulté le: 28 Janvier 2021]
47. MERAYO D, RODRÍGUEZ-PRIETO Á et CAMACHO A. Comparative analysis of artificial intelligence techniques for material selection applied to manufacturing in Industry 4.0. 31 Octobre 2019; 41:42-9. DOI : 10.1016/j.promfg.2019.07.027
48. S.N. AI technique could lead to development of new materials. *The Engineer*. 13 Février 2019. Accessible sur: <https://www.theengineer.co.uk/ai-technique-new-materials/> [Consulté le: 26 Février 2021]
49. WARD L, AGRAWAL A, CHOUDHARY A et WOLVERTON C. A general-purpose machine learning framework for predicting properties of inorganic materials. *Nature Publishing Group*. 26 Août 2016; 2:1-7. DOI : 10.1038/npjcompumats.2016.28. Accessible sur: <http://www.nature.com/articles/npjcompumats201628> [Consulté le: 17 Mars 2021]
50. MGI. Materials Genome Initiative. Accessible sur: <https://www.mgi.gov/> [Consulté le: 2 Avril 2021]
51. RAMPRASAD R, BATRA R, PILANIA G, MANNODI-KANAKKITHODI A et KIM C. Machine learning in materials informatics : recent applications and prospects. *npj Computational Materials*. 13 Décembre 2017; 3:1-13. DOI : 10.1038/s41524-017-0056-5. Accessible sur: <http://www.nature.com/articles/s41524-017-0056-5> [Consulté le: 17 Mars 2021]

52. BHANWAR S. The Most Common Machine Learning Regression Algorithms for Data Science. 24 Janvier 2021. Accessible sur: <https://medium.com/swlh/types-of-regression-algorithms-eb792039a554> [Consulté le: 2 Avril 2021]
53. SAYS J. A Quick Overview of Regression Algorithms in Machine Learning. Analytics Vidhya. 1 Octobre 2021. Accessible sur: <https://www.analyticsvidhya.com/blog/2021/01/a-quick-overview-of-regression-algorithms-in-machine-learning/> [Consulté le: 2 Avril 2021]
54. LIU Z, WU CT et KOISHI M. A deep material network for multiscale topology learning and accelerated nonlinear modeling of heterogeneous materials. Computer Methods in Applied Mechanics and Engineering. 1 Mars 2019; 345:1138-68. DOI : 10.1016/j.cma.2018.09.020. Accessible sur: <https://www.sciencedirect.com/science/article/pii/S0045782518304729> [Consulté le: 27 Février 2021]
55. TEPLA T, IZONIN I, DURIAGINA Z, TKACHENKO R, TROSTIANCHYN A, LEMISHKA I, KULYK V et KOVBASYUK T. Alloys selection based on the supervised learning technique for design of biocompatible medical materials. Archives of Materials Science and Engineering. 1 Septembre 2018; 1:32-40. DOI : 10.5604/01.3001.0012.6944
56. AUJESZKY T, KORRES G et EID M. Material classification with laser thermography and machine learning. 20 Décembre 2018 :181-202. Accessible sur: <https://www.tandfonline.com/doi/abs/10.1080/17686733.2018.1539895> [Consulté le: 2 Avril 2021]
57. KHARWAL A. Classification Algorithms in Machine Learning. The Clever Programmer. 30 Janvier 2021. Accessible sur: <https://thecleverprogrammer.com/2021/01/30/classification-algorithms-in-machine-learning/> [Consulté le: 2 Avril 2021]
58. LI H, KAFKA OL, GAO J, YU C, NIE Y, ZHANG L, TAJDARI M, TANG S, GUO X, LI G, TANG S, CHENG G et LIU WK. Clustering discretization methods for generation of material performance databases in machine learning and design optimization. Computational Mechanics. 1 Août 2019; 64:281-305. DOI : 10.1007/s00466-019-01716-0. Accessible sur: <https://doi.org/10.1007/s00466-019-01716-0> [Consulté le: 27 Février 2021]
59. YOSIPOF A, NAHUM OE, ANDERSON AY, BARAD HN, ZABAN A et SENDEROWITZ H. Data Mining and Machine Learning Tools for Combinatorial Material Science of All-Oxide Photovoltaic Cells. 20 Mars 2015. Accessible sur: <https://onlinelibrary.wiley.com/doi/abs/10.1002/minf.201400174> [Consulté le: 27 Février 2021]
60. ZHANG L, CHEN Z, SU J et LI J. Data mining new energy materials from structure databases. Renewable and Sustainable Energy Reviews. 1 Juin 2019; 107:554-67. DOI : 10.1016/j.rser.2019.03.036. Accessible sur: <https://www.sciencedirect.com/science/article/pii/S1364032119301777> [Consulté le: 17 Mars 2021]

61. TSHITOYAN V, DAGDELEN J, WESTON L, DUNN A, RONG Z, KONONOVA O, PERSSON KA, CEDER G et JAIN A. Unsupervised word embeddings capture latent knowledge from materials science literature. *Nature*. Juillet 2019; 571:95-8. DOI : 10.1038/s41586-019-1335-8. Accessible sur: <http://www.nature.com/articles/s41586-019-1335-8> [Consulté le: 27 Février 2021]
62. PEI Z, ZHANG D, ZHI Y, YANG T, JIN L, FU D, CHENG X, TERRY HA, MOL JMC et LI X. Towards understanding and prediction of atmospheric corrosion of an Fe/Cu corrosion sensor via machine learning. *Corrosion Science*. 1 Juillet 2020; 170:9. DOI : 10.1016/j.corsci.2020.108697. Accessible sur: <https://www.sciencedirect.com/science/article/pii/S0010938X20307265> [Consulté le: 5 Mars 2021]
63. GALVÃO TLP, NOVELL-LERUTH G, KUZNETSOVA A, TEDIM J et GOMES JRB. Elucidating Structure–Property Relationships in Aluminum Alloy Corrosion Inhibitors by Machine Learning. *The Journal of Physical Chemistry C*. 12 Mars 2020; 124:5624-35. DOI : 10.1021/acs.jpcc.9b09538. Accessible sur: <https://doi.org/10.1021/acs.jpcc.9b09538> [Consulté le: 5 Mars 2021]
64. WINKLER DA, BREEDON M, WHITE P, HUGHES AE, SAPPER ED et COLE I. Using high throughput experimental data and in silico models to discover alternatives to toxic chromate corrosion inhibitors. *Corrosion Science*. 1 Mai 2016; 106:229-35. DOI : 10.1016/j.corsci.2016.02.008. Accessible sur: <https://www.sciencedirect.com/science/article/pii/S0010938X16300415> [Consulté le: 5 Mars 2021]
65. YAN L, DIAO Y et GAO K. Analysis of Environmental Factors Affecting the Atmospheric Corrosion Rate of Low-Alloy Steel Using Random Forest-Based Models. *Multidisciplinary Digital Publishing Institute*. Janvier 2020; 13:3266. DOI : 10.3390/ma13153266. Accessible sur: <https://www.mdpi.com/1996-1944/13/15/3266> [Consulté le: 8 Avril 2021]
66. ZHI Y, FU D, ZHANG D, YANG T et LI X. Prediction and Knowledge Mining of Outdoor Atmospheric Corrosion Rates of Low Alloy Steels Based on the Random Forests Approach. *Multidisciplinary Digital Publishing Institute*. Mars 2019; 9:383. DOI : 10.3390/met9030383. Accessible sur: <https://www.mdpi.com/2075-4701/9/3/383> [Consulté le: 8 Avril 2021]
67. SHI J, WANG J et MACDONALD DD. Prediction of crack growth rate in Type 304 stainless steel using artificial neural networks and the coupled environment fracture model. *Corrosion Science*. Décembre 2014; 89:69-80. DOI : 10.1016/j.corsci.2014.08.011. Accessible sur: <https://linkinghub.elsevier.com/retrieve/pii/S0010938X14004004> [Consulté le: 12 Mars 2021]
68. KUMARI S, TIYYAGURA HR, DOUGLAS TEL, MOHAMMED EAA, ADRIAENS A, FUCHS-GODEC R, MOHAN MK et SKIRTACH AG. ANN prediction of corrosion behaviour of uncoated and biopolymers coated cp-Titanium substrates. *Materials & Design*. 5 Novembre 2018; 157:35-51.

- DOI : 10.1016/j.matdes.2018.07.005. Accessible sur: <https://www.sciencedirect.com/science/article/pii/S0264127518305355> [Consulté le: 5 Mars 2021]
69. KAMRUNNAHAR M et URQUIDI-MACDONALD M. Prediction of corrosion behavior using neural network as a data mining tool. Corrosion Science. 1 Mars 2010; 52:669-77. DOI : 10.1016/j.corsci.2009.10.024. Accessible sur: <https://www.sciencedirect.com/science/article/pii/S0010938X09005071> [Consulté le: 5 Mars 2021]
 70. DABOSI F, BÉRANGER G et BAROUX G. Corrosion localisée. EDP Sciences, 1994. Accessible sur: <https://unr-ra-scholarvox-com.docelec.insa-lyon.fr/catalog/book/docid/88805562?searchterm=corrosion> [Consulté le: 25 Avril 2021]
 71. BRICEÑO J, ROMEU A, ESPINAR E, LLAMAS JM et GIL FJ. Influence of the microstructure on electrochemical corrosion and nickel release in NiTi orthodontic archwires. Materials Science and Engineering : C. 1 Décembre 2013; 33:4989-93. DOI : 10.1016/j.msec.2013.08.024. Accessible sur: <https://www.sciencedirect.com/science/article/pii/S0928493113004876> [Consulté le: 29 Avril 2021]
 72. SPECIAL METALS. Product Handbook of High-Performance Nickel Alloys. Accessible sur: https://www.specialmetals.com/assets/smc/documents/PCC-8064%20SM%20AlloyHandbook_v07.pdf [Consulté le: 23 Avril 2021]
 73. BAYOUMI FM et GHANEM WA. Effect of nitrogen on the corrosion behavior of austenitic stainless steel in chloride solutions. Materials Letters. 1 Novembre 2005; 59:3311-4. DOI : 10.1016/j.matlet.2005.05.063. Accessible sur: <https://www.sciencedirect.com/science/article/pii/S0167577X05005483> [Consulté le: 22 Avril 2021]
 74. IANNUZZI M, RINCON-ORTIZ M, KAPPES M, RODRIGUEZ MA, CARRANZA R et REBAK R. Effect of Thermal Treatments on the Localized Corrosion Behavior of Alloy 718 (UNS N07718). About Corrosion. 2 Décembre 2013. Accessible sur: <https://www.aboutcorrosion.com/2013/12/02/alloy-718-localized-corrosion-abstract/> [Consulté le: 22 Avril 2021]
 75. STEEL TUBES INDIA. ERW Steel Tubes and Seamless Pipe manufacturers in India. STEEL TUBES India. Accessible sur: <https://www.stindia.com/> [Consulté le: 22 Avril 2021]
 76. SPECIAL METALS CORPORATION. Incoloy alloy 27-7Mo. 5 Décembre 2005. Accessible sur: https://www.hpalloy.com/Htmlpages/INCOLOY_alloy_27-7MO.html [Consulté le: 8 Février 2021]
 77. MISHRA A, RICHESIN D et REBAK R. Localized corrosion study of Ni-Cr-Mo alloys for oil and gas applications. NACE - International Corrosion Conference Series. 1 Janvier 2015
 78. OUVRAGE COLLECTIF. Nickel Alloys. Accessible sur: <https://nickelinstitute.org/about-nickel/nickel-alloys/> [Consulté le: 24 Avril 2021]

79. ZHANG J. Processing deformed microstructure and corrosion behavior of b10 Cu-Ni alloy., 2018. Accessible sur: <https://kns.cnki.net/kcms/detail/detail.aspx?dbcode=CMFD&dbname=CMFD201901&filename=1018126606.nh&v=jfduAenKxPZT703b%25mmd2BQWWQ0qzLQLRMA%25mmd2FjrLrVda> [Consulté le: 26 Avril 2021]
80. SHI Z, LIU B, LIU Y et XIE H. Progress of Corrosion Behavior and Anti-corrosion Technology for Typical Copper-nickel Alloys Under Marine Environment. . 2020; 17:38-44. Accessible sur: <https://kns.cnki.net/kcms/detail/detail.aspx?dbcode=CJFD&dbname=CJFDLAST2020&filename=JSCX202008006&v=1LHUYTLni5o6xLbX7FZ003X%25mmd2FsFAJqRlCBR0AyKVJ3WNq3pcmTtuX0F0L25mmd2BwCZp5pZ> [Consulté le: 26 Avril 2021]
81. LIU W, WU Y, MA Y, ZHANG J, YE X et TIAN H. Electrochemical corrosion behavior of amorphous Ni_{42.2}W_{19.2}Fe_{18.9}B_{19.7} alloy. . 2015; 25:2123-30. Accessible sur: <https://kns.cnki.net/kcms/detail/detail.aspx?dbcode=CJFD&dbname=CJFDLAST2015&filename=ZYZX201508012&v=AmSrSniL%25mmd2B7ilnEXwd%25mmd2B04Uf%25mmd2FTJKRrZiIgygVdIYhhI4p9nQ5Ep1m25mmd2BgAoSzcX> [Consulté le: 26 Avril 2021]
82. MA Q, YANG Q et ZHOU J. Accessible sur: <http://www.cspt.org.cn/article/2015/1002-6495/1002-6495-27-401.shtml> [Consulté le: 26 Avril 2021]
83. CHANG Q, CHEN Y, SONG F et PENG T. Corrosion Properties of B30 Cu-Ni Alloy and 316L Stainless Steel in a Heat Pump System. . 23 Juillet 2015; 34:544-9. DOI : 10.11902/1005.4537.2013.221. Accessible sur: <https://www.jscsp.org/CN/abstract/abstract23205.shtml> [Consulté le: 26 Avril 2021]
84. CROOK P. A Guide to the Metallurgical, Corrosion, and Wear Characteristics of the Wrought Nickel and Cobalt Alloys. 2020. Accessible sur: https://www.haynesintl.com/docs/default-source/pdfs/new-alloy-brochures/a-guide-to-the-metallurgical-corrosion-and-wear-characteristics.pdf?sfvrsn=413606d4_8 [Consulté le: 10 Avril 2020]
85. CROOK P. Corrosion resistant nickel alloys. 2007. Accessible sur: <https://www.asminternational.org/documents/10192/1879877/amp16508p045.pdf/23978373-7c06-4735-9ffe-dacdab4aa8ab> [Consulté le: 20 Avril 2021]
86. KLAPPER H, ZADOROZNE N et REBAK R. Localized Corrosion Characteristics of Nickel Alloys : A Review. Acta Metallurgica Sinica (English Letters). 2 Mars 2017; 30. DOI : 10.1007/s40195-017-0553-z
87. OUVRAGE COLLECTIF. Choosing the right estimator. Scikit-learn.org. Accessible sur: https://scikit-learn.org/stable/tutorial/machine_learning_map/index.html?fbclid=IwAR3nQ1ZiLbBMmgafjd7Q90EhxavMYUmayrLDbLUe1GErNQwyXrF8a4aawiU [Consulté le: 29 Mars 2021]

88. XLSTAT. Comparaison d'algorithmes de Machine Learning supervisé. XLSTAT by Addinsoft. Accessible sur: https://help.xlstat.com/s/article/comparison-of-supervised-machine-learning-algorithms?language=fr&fbclid=IwAR20VAvPZ_3bxz6e3pUFT5d-88iZnOVHQB14-BrR7XEN2hr1cocMC0-Sf0I [Consulté le: 29 Mars 2021]
89. VIEILLE MJ. Random Forest, tutoriel avec Python. Lovely Analytics. 8 Juin 2020. Accessible sur: <https://www.lovelyanalytics.com/2020/06/08/random-forest-tutoriel-python/> [Consulté le: 8 Avril 2021]
90. MOYANO C. Learn the Anti-corrosion code. Barnstaple (UK) : Parker Hannifin Corporation, 2017. [Consulté le: 2 Avril 2021]
91. DAKE et GGAL. Austénite. *Wikipédia*. 16 Mai 2020. Accessible sur: <https://fr.wikipedia.org/w/index.php?title=Aust%C3%A9nite&oldid=170943387> [Consulté le: 28 Avril 2021]
92. INTERNATIONAL MOLYBDENUM ASSOCIATION (OUVRAGE COLLECTIF). Guide pratique pour le travail des aciers inoxydables duplex. Londres : International Molybdenum Association, 2011. 64 p. [Consulté le: 8 Avril 2021]
93. NEONICKEL. PREn - Pitting Resistance Equivalent Number. Accessible sur: <https://www.neonickel.com/technical-resources/general-technical-resources/pren-pitting-resistance-equivalent-number/> [Consulté le: 2 Avril 2021]
94. MONS C. Traitements thermiques des superalliages. *Techniques de l'Ingénieur*. Editions T.I. 10 Avril 1996. Accessible sur: <https://www-techniques-ingenieur-fr.docelec.insa-lyon.fr/base-documentaire/materiaux-th11/traitements-thermiques-des-aciers-des-alliages-et-des-fontes-42364210/traitements-thermiques-des-superalliages-m1165/superalliages-m1165niv10001.html> [Consulté le: 10 Avril 2021]
95. SWAGELOK. Simplifier la sélection des matériaux, Votre guide pour faire des choix qui vont limiter l'impact de la corrosion. Accessible sur: <https://www.swagelok.com/downloads/webcatalogs/fr/CORP-0171.PDF> [Consulté le: 23 Avril 2021]